

Inteligență Artificială

Universitatea Politehnica Bucuresti
Anul universitar 2021-2022

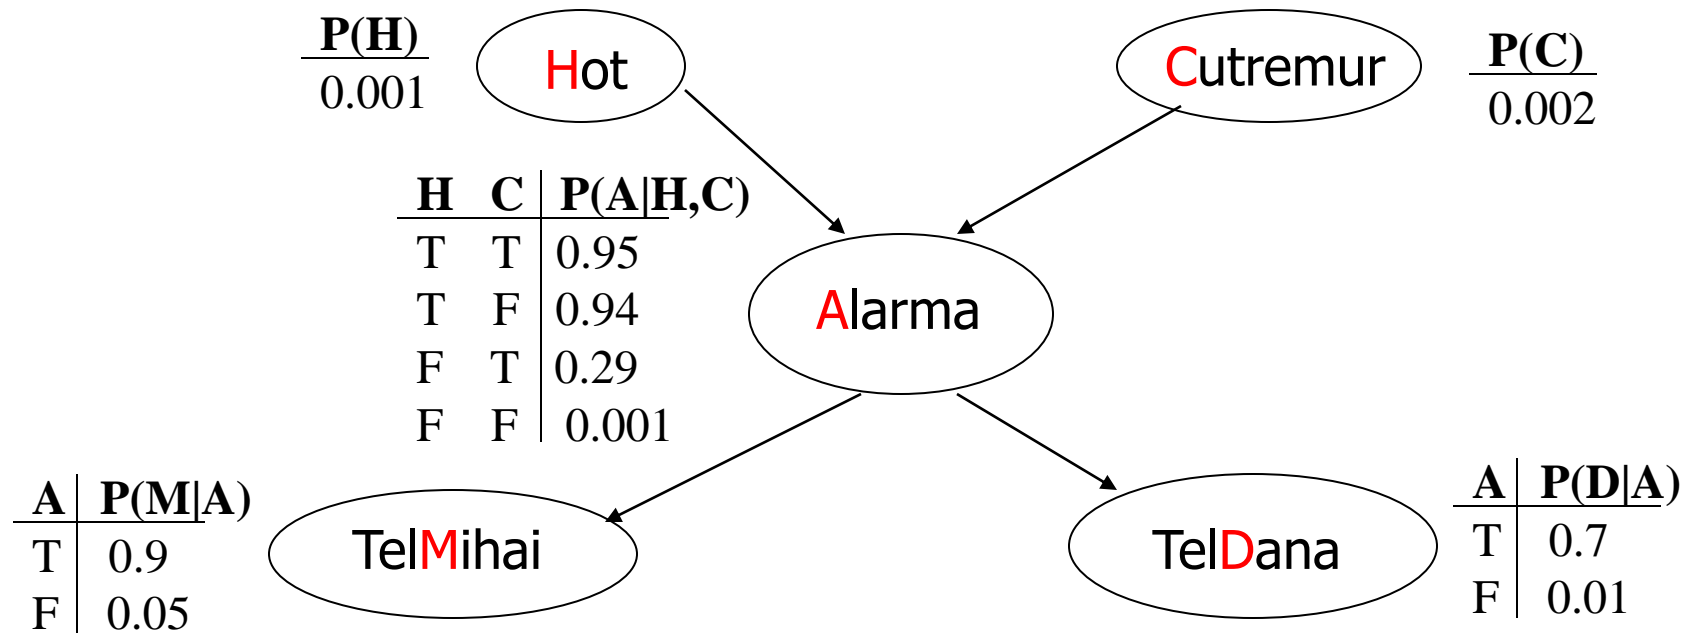
Adina Magda Florea

Curs nr. 5 si 6

Reprezentarea cunostintelor incerte


- Teoria probabilitatilor
- Retele Bayesiene
- Inferente exacte si aproximative in retele Bayesiene

Inferente probabilistică




$$\begin{aligned}
 &P(M \wedge D \wedge A \wedge \sim H \wedge \sim C) = \\
 &P(M|A) * P(D|A) * P(A|\sim H \wedge \sim C) * P(\sim H) \wedge P(\sim C) = \\
 &0.9 * 0.7 * 0.001 * 0.999 * 0.998 = 0.00062
 \end{aligned}$$

Inferente probabilistică



$$\begin{aligned}
 P(A|H) &= P(A|H,C) * P(C|H) + P(A|H,\sim C) * P(\sim C|H) \\
 &= P(A|H,C) * P(C) + P(A|H,\sim C) * P(\sim C) \\
 &= 0.95 * 0.002 + 0.94 * 0.998 = 0.94002
 \end{aligned}$$

2.5 Inferență prin enumerare



X – variabila de interogare (Carie)

E – lista de variabile probe (Dur_d)

e – lista valorilor observate pt aceste variabile E

Y – lista variabilelor neobservate (restul) (Evid)

$$\mathbf{P}(X \mid e) = \alpha \mathbf{P}(X, e) = \alpha \Sigma_Y \mathbf{P}(X, e, Y)$$

$$\mathbf{P}(\mathbf{H}|\mathbf{M},\mathbf{D}) = \alpha \mathbf{P}(H,M,D) =$$

$$\alpha \Sigma_C \Sigma_A \mathbf{P}(H)\mathbf{P}(C)\mathbf{P}(A|H,C)\mathbf{P}(M|A)\mathbf{P}(D|A)$$

n var bool $\rightarrow O(2^n)$

Inferență prin enumerare

$$P(\mathbf{H}|\mathbf{M},\mathbf{D}) = \alpha \sum_C \sum_A P(H)P(C)P(A|H,C)P(M|A)P(D|A)$$

$$\begin{aligned} P(H|M,D) &= \alpha P(H) \sum_C P(C) \sum_A P(A|H,C)P(M|A)P(D|A) \\ &= \alpha \langle 0.00059224, 0.0014919 \rangle =_{\text{aprox}} \langle 0.284, 0.716 \rangle \end{aligned}$$

Complexitate spatiu – $O(n)$

Complexitate timp $O(2^n)$

Inferență prin enumerare - algoritm

algoritm Enumerare(X,e,rb) intoarce distributie X

X – var de interogare

e – valori observate pt E

rb – Retea Bayesiană cu var $\{X\} \cup E \cup Y$

1. $Q(X) \leftarrow$ o distributie X, initial vida
 2. **pentru** fiecare valoare x_i a lui X **repeta**
 $Q(x_i) \leftarrow$ **EnumToate**(rb.Vars, e_{x_i})
 unde e_{x_i} este **e** extins cu $X=x_i$
 3. **intoarce** Normalizare($Q(x)$)
- sfarsit**

Inferență prin enumerare - algoritm

algoritm EnumToate(Vars,e) intoarce un numar real


1. daca $\text{Vars} = []$ atunci intoarce 1.0
2. $Y \leftarrow \text{first}(\text{Vars})$
3. **daca** Y are valoare y in e
atunci intoarce $P(y|\text{parinti}(Y)) * \text{EnumToate}(\text{Rest}(\text{Vars}),e)$
altfel intoarce

$$\sum_y P(y|\text{parinti}(Y)) * \text{EnumToate}(\text{Rest}(\text{Vars}),e_y)$$


unde e_y este e extins cu $Y=y$

sfarsit

$$P(\mathbf{H}|\mathbf{M},\mathbf{D}) = \alpha \sum_C \sum_A P(H)P(C)P(A|H,C)P(M|A)P(D|A)$$



$$\mathbf{P}(X \mid e) = \alpha \mathbf{P}(X, e) = \alpha \sum_Y \mathbf{P}(X, e, Y)$$



$$\mathbf{P}(\mathbf{H}|\mathbf{M},\mathbf{D}) = \alpha \sum_C \sum_A P(H)P(C)P(A|H,C)P(M|A)P(D|A)$$

Eliminarea variabilelor (Variable elimination)

Pt a elimina calculele duplicate – se calculeaza o data si se salveaza rezultatul

Idee – se calculeaza ecuatia de la dreapta la stanga

$$P(H|M,D) = \alpha \sum_C \sum_A P(H) P(C) P(A|H,C) P(M|A) P(D|A)$$

$f1(H) \quad f2(C) \quad f3(A,H,C) \quad f4(A) \quad f5(A)$

$$f5(A) = [P(D|A) \quad P(D|\sim A)] = [.07 \quad .001]$$

$$f4(A) = [P(M|A) \quad P(M|\sim A)] = [.09 \quad .05]$$

$f3(A,H,C)$ va fi o matrice de $2 \times 2 \times 2$

$$[P(A|H,C) \quad P(\sim A|H,C) \quad P(A|H, \sim C) \quad P(\sim A|H, \sim C) \quad \dots \quad P(\sim A|\sim H, \sim C)]$$

Eliminarea variabilelor

$$P(H|M,D) = \alpha \sum_C \sum_A \frac{P(H) P(C) P(A|H,C) P(M|A) P(D|A)}{f1(H) f2(C) f3(A,H,C) f4(A) f5(A)}$$

Insumam peste A in f3, f4, f5 – rezulta un factor **f6(H,C)**

$$\mathbf{f6(H,C)} = \sum_A \mathbf{f3(A,H,C)} \times \mathbf{f4(A)} \times \mathbf{f5(A)} =$$

$$\mathbf{f3(a,H,C)} \times \mathbf{f4(a)} \times \mathbf{f5(a)} + \mathbf{f3(\sim a,H,C)} \times \mathbf{f4(\sim a)} \times \mathbf{f5(\sim a)}$$

Insumam peste C – rezulta un factor **f7(H)**

$$P(H|M,D) = \alpha \mathbf{f1(H)} \times \sum_C \mathbf{f2(C)} \times \mathbf{f6(H,C)}$$

$$\mathbf{f7(H)} = \sum_C \mathbf{f2(C)} \times \mathbf{f6(H,C)} = \mathbf{f2(c)} \times \mathbf{f6(H,c)} + \mathbf{f2(\sim c)} \times \mathbf{f6(H,\sim c)}$$

$$P(H|M,D) = \alpha \mathbf{f1(H)} \times \mathbf{f7(H)}$$

Avem nevoie de 2 operatii

- **Pointwise product** \times
- **Insumarea unei variabile dintr-un produs de factori**

Implementarea operațiilor

Pointwise product

$$(\mathbf{f}_1 \times \mathbf{f}_2)(X_1, \dots, X_i, Y_1, \dots, Y_j, Z_1, \dots, Z_k) = \\ \mathbf{f}_1(X_1, \dots, X_i, Y_1, \dots, Y_j) \times \mathbf{f}_2(Y_1, \dots, Y_j, Z_1, \dots, Z_k)$$

Insumarea unei variabile dintr-un produs de factori

- Insumarea peste **X1**, rezultatul este un factor peste X_2, \dots, X_i

$$(\sum_{X_1} \mathbf{f})(X_2, \dots, X_i) = \mathbf{f}(X_1=v_1, \dots, X_i) + \dots + \mathbf{f}(X_1=v_k, \dots, X_i)$$

Implementarea operațiilor - exemplu

Pointwise product

$f1(A,B) \times f2(B,C) = f3(A,B,C)$ are $2^{1+1+1} = 8$ intrari

A	B	f1(A,B)	B	C	f2(B,C)	A	B	C	f3(A,B,C)
a	a	.3	a	a	.2	a	a	a	.3 x .2 = .06
a	f	.7	a	f	.8	a	a	f	.3 x .8 = .24
f	a	.9	f	a	.6	a	f	a	.7 x .6 = .42
f	f	.1	f	f	.4	a	f	f	.7 x .4 = .28
						f	a	a	.9 x .2 = .18
						f	a	f	.9 x .8 = .72
						f	f	a	.1 x .6 = .06
						f	f	f	.1 x .4 = .04

Implementarea operațiilor - exemplu


Insumarea unei variabile dintr-un produs de factori

- Insumarea peste A din $f_3(A,B,C)$

$$f(B,C) = \sum_A f_3(A,B,C) = f_3(a,B,C) + f_3(\sim a,B,C) =$$

$$\begin{bmatrix} .06 & .24 \\ .42 & .28 \end{bmatrix} + \begin{bmatrix} .18 & .72 \\ .06 & .04 \end{bmatrix} = \begin{bmatrix} .24 & .96 \\ .48 & .32 \end{bmatrix}$$

2.6 Tipuri de inferență




Inferente de diagnosticare (efect \rightarrow cauza)

$P(\text{Hot} \mid \text{TelMihai})$

Inferente cauzale (cauza \rightarrow efect)

$P(\text{TelMihai} \mid \text{Hot}), P(\text{TelDana} \mid \text{Hot})$

Tipuri de inferență



Inferente intercauzale (intre cauza si efecte comune)

$$P(\text{Hot} \mid \text{Alarma} \wedge \text{TelDana})$$

Inferente mixte

$$P(\text{Alarma} \mid \text{TelMihai} \wedge \sim \text{Cutremur}) \rightarrow \text{diag} + \text{cauzal}$$

$$P(\text{Hot} \mid \text{TelMihai} \wedge \sim \text{Cutremur}) \rightarrow \text{diag} + \text{intercauzal}$$

2.7 Independenta in RB

- Evenimentele **X** si **Y** sunt **independente conditional** fiind dat **un eveniment Z** daca

Stiind ca **Z** apare, aparitia lui **X** nu influenteaza aparitia lui **Y** si aparitia lui **Y** nu influenteaza aparitia lui **X**

- Structura de graf RB codifica anumite relatii de **independenta**: fiecare nod este **independent conditional** de **nondescendenti**, fiind dati parintii lui

Independenta in RB

- Mai sunt si alte relatii de independenta?
- Doua sau mai multe relatii de independenta conditionala pot conduce la o noua relatie folosind un mecanism bazat pe axiome ale grafurilor
- **D-separabilitatea** este un concept care surprinde astfel de relatii de independenta conditionala derivate
- Z **d-separa** pe X si Y intr-un DAG daca X si Y sunt independente conditional fiind dat Z dpv al axiomelor grafului.
- $(X \perp Y \mid Z)$ – X este independent conditional de Y fiind dat Z

D-separabilitate

D-separabilitate

- Cand nu este indeplinita $(X \perp Y \mid Z)$?

Conexiuni directe $X \rightarrow Y$

- Se pot influenta indiferent de Z

Conexiuni indirecte: X si Y nu sunt direct conectate dar exista un lant intre ele (trail)


D-separabilitate

- Fie cazul a 3 noduri

Caz a: Efect cauzal


Lantul cauzal $X \rightarrow Z \rightarrow Y$

- X nu influenteaza Y via Z daca Z observat



Caz b: Efect evidenta


- $Y \rightarrow Z \rightarrow X$
- Identic cu cazul **a**:
- X nu influenteaza Y via Z daca Z observat
- **daca $(X \perp Y \mid Z)$ nu este indeplinit atunci nici $(Y \perp X \mid Z)$ nu este indeplinit**



D-separabilitate


Caz c: Cauza comuna

- $X \leftarrow Z \rightarrow Y$
- X nu influenteaza pe Y via Z daca Z observat



Case d: Efect comun

- $X \rightarrow Z \leftarrow Y$
- Influenta nu poate merge de-a lungul lantului $X \rightarrow Z \leftarrow Y$ daca Z nu este observat

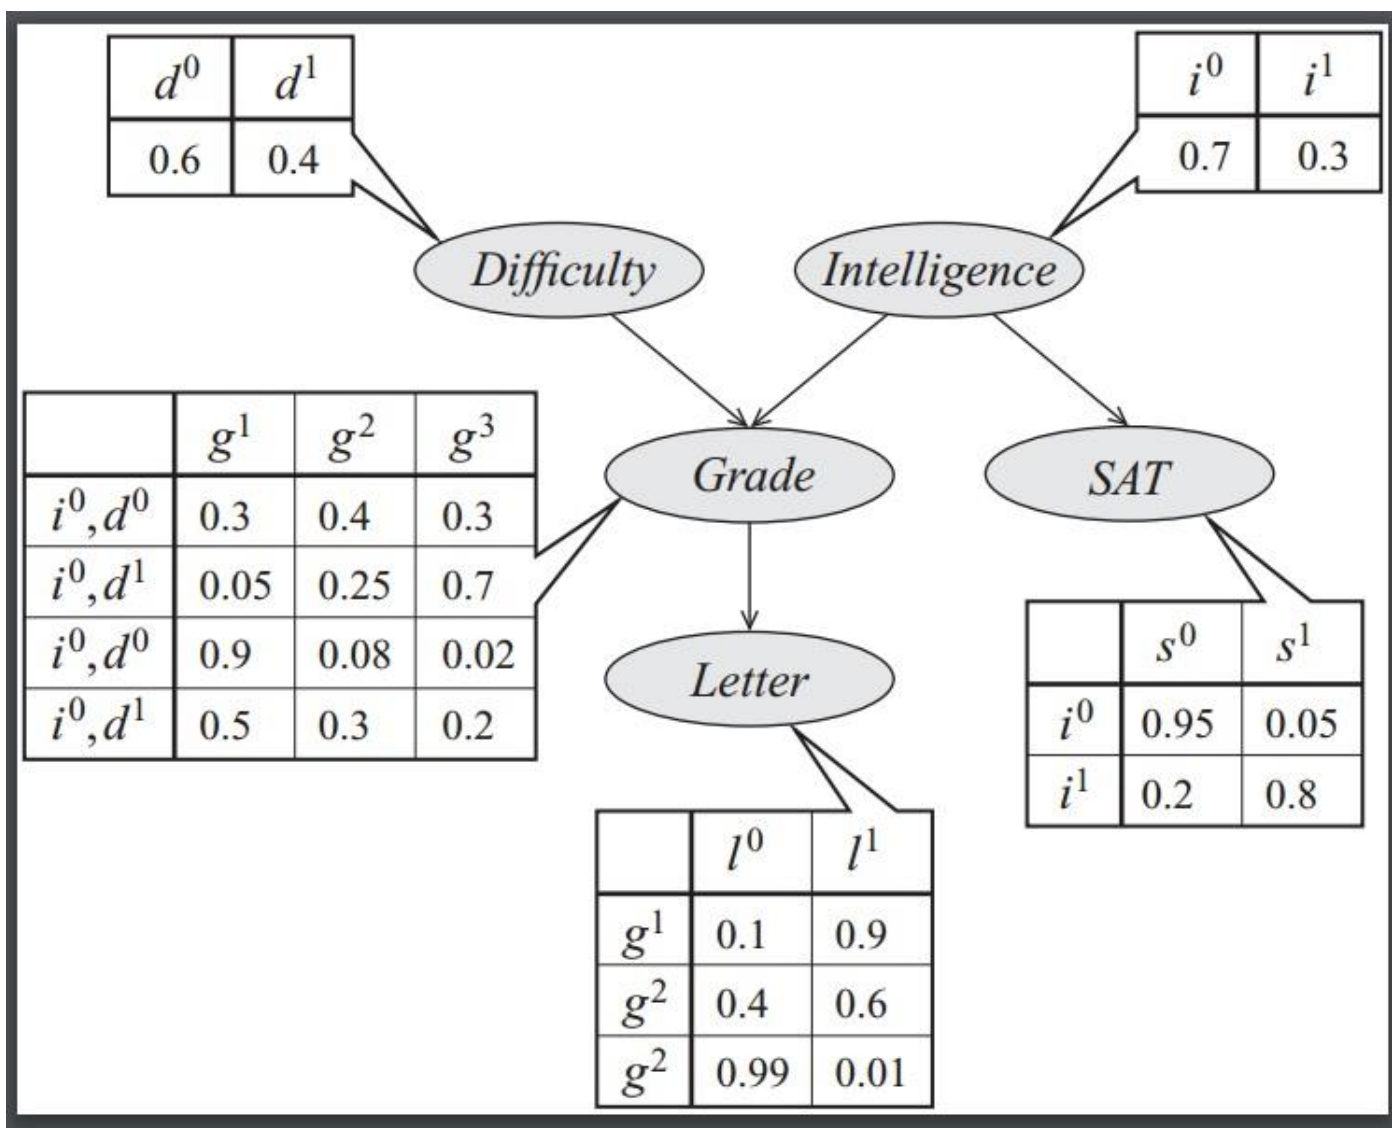


Deci X nu influenteaza pe Y via Z daca Z NU este observat

D-separabilitate

Daca influenta poate curge de la X la Y via Z spunem ca lantul $X \leftrightarrow Z \leftrightarrow Y$ este activ

- Efect cauzal $X \rightarrow Z \rightarrow Y$ – activ \leftrightarrow Z nu este observat
- Efect evidenta $Y \rightarrow Z \rightarrow X$ – activ \leftrightarrow Z nu este observat
- Cauza comuna $X \leftarrow Z \rightarrow Y$ – activ \leftrightarrow Z nu este observat
- Efect comun $X \rightarrow Z \leftarrow Y$ - activ \leftrightarrow fie Z fie unul din descendentii lui Z este observat
- **Influenta probabilistica = flux in graf** – cand influenta din X poate curge prin Z catre Y a.i. sa afecteze probabilitatea lui Y,
- Deci X nu este conditional independent de Y fiind dat Z



2.8 Inferențe de aproximare în RB

- Inferențe exacte în RB:
 - Inferența prin enumerare
 - Eliminarea variabilelor (eficientizare)

Asa cum s-a aratat anterior, exprimam probabilitatea conditionata ca probabilitate neconditionata, apoi insumam peste variabilele neobservate

$$\mathbf{P}(X \mid e) = \alpha \mathbf{P}(X, e) = \alpha \sum_Y \mathbf{P}(X, e, Y)$$

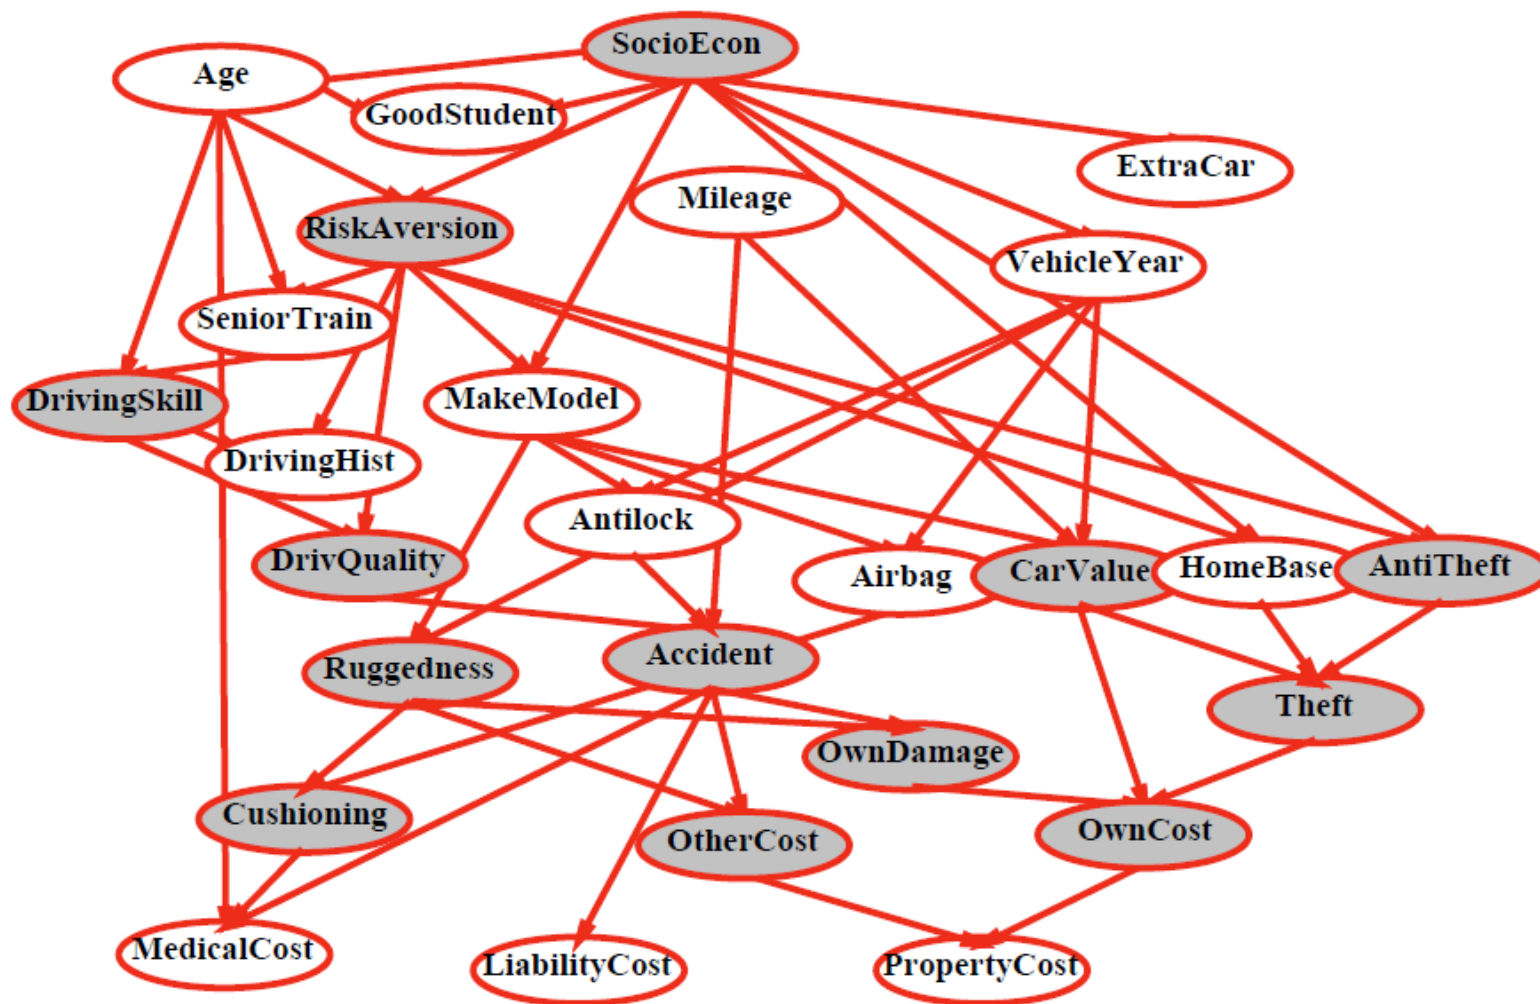
Inferente de aproximare in RB

Inferente exacte in RB foarte costisitoare

- Complexitate spatiu – $O(n)$
- Complexitate timp $O(2^n)$ – pt n variabile booleene

Pentru retele complexe aceste metode devin de multe ori nepractice

Asigurarea auto



Inferențe de aproximare

Inferente de aproximare

- Algoritmi de esantionare aleatoare, cunoscuti si ca algoritmi Monte Carlo
- Oferă raspunsuri aproximative care depind de numarul de esantioane care se genereaza
- Ne intereseaza esantionare pentru calculul probabilitatilor conditionate

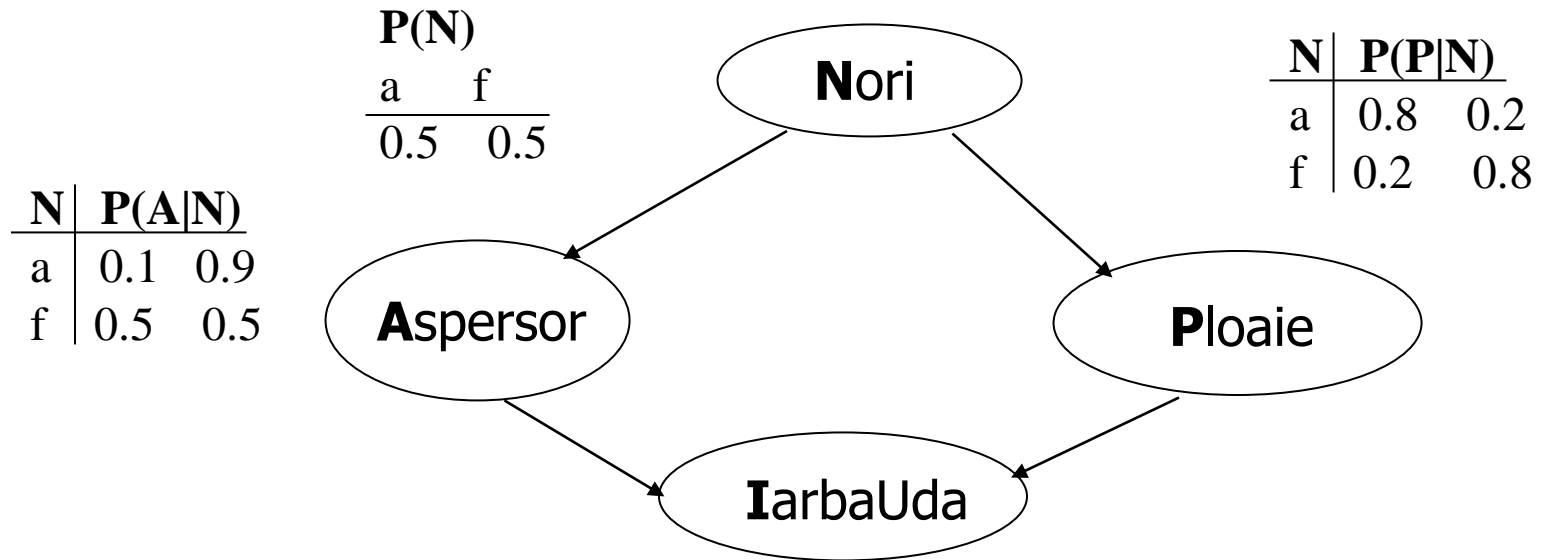
Esantionare directa

Esantionare cu lanturi Markov

a) Esantionare directa

- Se genereaza esantioane dintr-o distributie de probabilitate cunoscuta
- Cel mai simplu proces de esantionare intr-o RB genereaza esantioane/evenimente din retea fara nici o proba
- Ideea este de a esantiona fiecare variabila pe rand in ordine topologica
- Distributia de probabilitate din care se obtin valorile unei variabile din esantion este conditionata de valorile care au fost deja atribuite parintilor

RB exemplu



A	P	P(I A, P)	
		a	f
a	a	0.99	0.01
a	f	0.9	0.1
f	a	0.9	0.1
f	f	0.1	0.9


Generarea esantionului

Presupun ordinea [*Nori*, *Aspersor*, *Ploaie*, *IarbaUda*]

1. Esantion $\mathbf{P(Nori)} = \langle 0.5 \ 0.5 \rangle$ **a**
2. Esantion din $\mathbf{P(Aspersor|Nori=a)} = \langle 0.1 \ 0.9 \rangle$ **f**
3. Esantion $\mathbf{P(Ploaie|Nori=a)} = \langle 0.8 \ 0.2 \rangle$ **a**
4. Esantion din $\mathbf{P(IarbaUda|Aspersor=f, Ploaie=a)} = \langle 0.9 \ 0.1 \rangle$ **a**

Esantionarea este [**a**, **f**, **a**, **a**]

RB exemplu



A	P	P(I A, P)	
		a	f
a	a	0.99	0.01
a	f	0.9	0.1
f	a	0.9	0.1
f	f	0.1	0.9

Algoritm de esantionare

algoritm Esantionare(rb) intoarce esantion

intrari: rb specificand d.p. $P(X_1, \dots, X_N)$

$x \leftarrow$ esantion cu n elemente

pentru fiecare variabila X_i din X_1, \dots, X_N **repeta**

$x[i] \leftarrow$ un esantion aleator din $P(X_i | \text{parinti}(X_i))$

intoarce x

sfarsit

Algoritm de esantionare

- Intr-un algoritm de esantionare, raspunsurile sunt calculate prin numararea numarului de esantioane generate
- Sa presupunem ca avem N esantionari

$N_{PS}(x_1, \dots, x_n)$ – de cate ori a aparut x_1, \dots, x_n in multimea de esantioane

- Se presupune ca acest numar va converge chiar la probabilitate

$$\lim_{N \rightarrow \infty} (N_{PS}(x_1, \dots, x_n)/N) = P(x_1, \dots, x_n)$$

- Fie S_{PS} probabilitatea ca un eveniment(esantion) specific sa fie generat de algoritmul de esantionare

$$S_{PS}(x_1, \dots, x_n) = \prod_{i=1, n} P(x_i | \text{parinti}(X_i)) = P(x_1, \dots, x_n)$$

deoarece fiecare pas de esantionare depinde de valorile parintilor

Algoritm de esantionare

$$S_{PS}(x_1, \dots, x_n) = \prod_{i=1, n} P(x_i | \text{parinti}(X_i)) = P(x_1, \dots, x_n)$$

$$\lim_{N \rightarrow \infty} (N_{PS}(x_1, \dots, x_n) / N) = S_{PS}(x_1, \dots, x_n) = P(x_1, \dots, x_n)$$

De exemplu sa consideram esantionul

[a, f, a, a] generat anterior

Probabilitatea de esantionare a acestui eveniment

$$S_{PS}(a, f, a, a) = 0.5 \times 0.9 \times 0.8 \times 0.9 = 0.324$$

Pentru N foarte mare, putem presupune ca 32,4% din esantioane vor fi egale cu acesta

b) Eliminarea esantioanelor nepotrivite

Eliminarea esantioanelor (*Rejection sampling*)

- Se refera la situatia in care avem de estimat o probabilitate conditionata $P(X|e)$
- Se genereaza esantioanele din distributia de probabilitate specificata de retea
- Apoi se elimina acele esantioane care nu se potrivesc cu probele e
- In final estimarea lui $P(X=x|e)$ este obtinuta prin numararea numarului de aparitii $X=x$ in esantioanele ramase

Eliminarea esantioanelor nepotrivite

- Dorim sa estimam

$$P(\text{Ploaie}|\text{Aspersor} = a)$$

- Generam, de ex, 100 esantioane
- Presupunem ca din cele 100 esantioane 73 au $\text{Aspersor} = f$, le eliminam
- Raman 27 cu $\text{Aspersor} = a$
- Din acestea 8 au $\text{Ploaie} = a$ si 19 au $\text{Ploaie} = f$
- $P(\text{Ploaie}|\text{Aspersor} = a) = \text{Normalizare}(\langle 8, 19 \rangle) = \langle 0.296, 0.704 \rangle$

Rapunsul corect este $\langle 0.3, 0.7 \rangle$

- Pe masura ce colectam mai multe esantioane, raspunsul va converge catre valoarea reala

Algoritm de esantionare cu eliminare

algoritm EsantionareEliminare(X, e, rb, N)

intoarce o estimare $P(X|e)$

intrari: rb specificand d.p. $P(X_1, \dots, X_N)$

X – variabila de interogare

e – valorile observate pentru variabilele E

N – numarul total de esantioane generate

variabile locale VN – vector care numara aparitiile valorilor lui X

pentru $j \leftarrow 1, N$ **repeta**

$y \leftarrow$ Esantionare (rb)

daca y este consistent cu e **atunci**


$VN[x] \leftarrow VN[x] + 1$ unde x este valoarea lui X in y

intoarce Normalizare(VN)

sfarsit

Eliminarea esantioanelor nepotrivite

- Principala problema a acestei abordari este faptul ca elimina prea multe esantioane



- Esantioane pt $P(\text{Cutremur}|\text{Alarma}=a)$

~~Cutremur = f, Alarma = f~~

~~Cutremur = f, Alarma = f~~

~~Cutremur = f, Alarma = f~~

Cutremur = a, Alarma = a

- Procentul de esantioane consistent cu probele scade exponential pe masura ce creste numarul de probe, deci problematic pentru probleme complexe

c) Esantionarea ponderata

Esantionare ponderata (*Likelihood weighting*)

- Elimina ineficienta potentiala a eliminarii esantioanelor prin generarea numai a acelor **evenimente** (esantioane) care sunt **consistente cu probele**
- Se fixeaza valorile variabilelor probe **E** si se esantioneaza numai pentru celelalte variabile
- Acest lucru garanteaza faptul ca fiecare esantion generat este consistent cu probele; dar nu toate evenimentele sunt la fel de importante

Esantionarea ponderata

- Inainte de a le numara, fiecare eveniment este ponderat cu o **plauzibilitate** (likelihood) pe care esantionul o acorda probei
- **Plauzibilitatea (likelihood)** este masurata ca **produsul probabilitatilor conditionate pentru fiecare variabila proba, fiind dati parintii ei**

Esantionarea ponderata - Exemplu

$$P(\text{Ploaie}|\text{Nori}=\mathbf{a}, \text{IarbaUda}=\mathbf{a})$$

si ordonarea $[\text{Nori}, \text{Aspersor}, \text{Ploaie}, \text{IarbaUda}]$

Initial $w=1.0$

Se genereaza un esantion


1. *Nori* este o variabila proba cu valoarea \mathbf{a}

In consecinta $\mathbf{w} \leftarrow \mathbf{w} \times P(\text{Nori}=\mathbf{a}) = 0.5$

2. *Aspersor* nu este o variabila proba deci esantionam

$P(\text{Aspersor}|\text{Nori}=\mathbf{a}) = (0.1, 0.9)$ - presupun \mathbf{f}

3. Similar $P(\text{Ploaie}|\text{Nori}=\mathbf{a}) = (0.8, 0.2)$ - presupun \mathbf{a}



$P(\mathbf{A} \mathbf{N})$	
\mathbf{N}	$\mathbf{P}(\mathbf{A} \mathbf{N})$
a	0.1 0.9
f	0.5 0.5

$P(\mathbf{N})$	
\mathbf{a}	\mathbf{f}
0.5	0.5

$\mathbf{N} \mid P(\mathbf{P} \mathbf{N})$	
\mathbf{a}	\mathbf{f}
0.8	0.2
0.2	0.8

$\mathbf{A} \mid \mathbf{P}$		$P(\mathbf{I} \mathbf{A}, \mathbf{P})$	
\mathbf{a}	\mathbf{f}	\mathbf{a}	\mathbf{f}
a	a	0.99	0.01
a	f	0.9	0.1
f	a	0.9	0.1
f	f	0.1	0.9

Esantionarea ponderata - Exemplu


$P(\text{Ploaie}|\text{Nori}=\text{a}, \text{IarbaUda}=\text{a})$

si ordonarea $[\text{Nori}, \text{Aspersor}, \text{Ploaie}, \text{IarbaUda}]$

4. *IarbaUda* este o variabila proba cu valoarea **a**

$$w \leftarrow w \times P(\text{IarbaUda}=\text{a} \mid \text{Aspersor}=\text{f}, \text{Ploaie}=\text{a}) = 0.9 \times 0.5 = 0.45$$

Esantionarea ponderata intoarce un esantion **$[\text{a}, \text{f}, \text{a}, \text{a}]$** cu ponderea **0.45** in conditiile $\text{Ploaie}=\text{a}$



A	P	$P(I A, P)$	
		a	f
a	a	0.99	0.01
a	f	0.9	0.1
f	a	0.9	0.1
f	f	0.1	0.9

Algoritm de esantionare ponderata

algoritm EsantionarePonderata(X, e, rb, N)

intoarce o estimare $P(X|e)$

intrari: rb specificand d.p. $P(X_1, \dots, X_N)$

X – variabila de interogare

e – valorile observate pentru variabilele E

N – numarul total de esantioane generte

variabile locale W – vector care numara aparitiile valorilor lui X ,
ponderate

pentru $j \leftarrow 1, N$ **repeta**

$x, w \leftarrow \text{Esantion-Ponderat}(rb, e)$

$W[x] \leftarrow W[x] + w$ unde x este valoarea lui X in x

intoarce Normalizare(W)

sfarsit

Algoritm de esantionare ponderata

algoritm Esantion-Ponderat(rb,e)

intoarce un esantion si o pondere

$w \leftarrow 1$

$\mathbf{x} \leftarrow$ un esantion cu n elemente initializate din e

pentru fiecare variabila X_i din X_1, \dots, X_n **repeta**

daca X_i este o variabila proba cu valoarea x_i in e

atunci $w \leftarrow w * P(X_i = x_i \mid \text{parinti}(X_i))$

altfel $\mathbf{x}[i] \leftarrow$ un esantion aleator din $P(X_i \mid \text{parinti}(X_i))$

intoarce \mathbf{x}, w

sfarsit