

Teste de curs

SVM

1. Se considera un SVM cu Kernel polinomial de grad 2 care se aplica pe un set de date si se obtine o acuratete de 100%. Daca se creste gradul polinomului Kernel ce se va intampla?

- a. Nu se va observa nici o modificare
- b. Cresterea complexitatii va duce la underfitting
- c. SVM-ul nu mai poate clasifica
- d. Cresterea complexitatii va duce la overfitting**

2. Avem o problema de clasificare cu 4 clase si utilizam un SVM cu metoda One-vs-all. De cate ori trebuie sa antrenam modelul?

- a. 1
- b. 2
- c. 3
- d. 4**

3. Se antreneaza un SVM care obtine o acuratete foarte mare pentru un anumit set de date de antrenare si o acuratete mica pentru datele de validare. Care din urmatoarele afirmatii este adevarata?

- a. Este un exemplu de overfitting**
- b. Sunt prea multe exemple de test
- c. Sunt prea multe exemple de antrenare
- d. Este un exemplu de underfitting

4. Odata ce aflam multiplicatorii Lagrange, cum se poate executa clasificarea?

- a. Nu putem face clasificare
- b. Se calculeaza b si apoi se calculeaza functia de clasificare pe baza lui b si a exemplelor de invatare**
- c. Se calculeaza functia de clasificare pe baza multiplicatorilor Lagrange si a exemplelor de invatare
- d. Se calculeaza b si apoi se calculeaza w pe baza lui b

5. Numarul de exemple de test necesare pentru a obtine rezultate semnificativ statistice intr-o clasificare cu SVM trebuie sa fie:

- a. nu depinde de rata de eroare
- b. mare daca rata de eroare este mica**
- c. mare daca rata de eroare este mare

6. Cum afecteaza distanta dintre punctele exemple pozitive si punctele exemple negative marginea de separare?

- a. **Cu cat sunt mai departe unele de altele cu atat marginea de separare este mai mare**
- b. Nu afecteaza marginea de separare
- c. Cu cat sunt mai departe unele de altele cu atat marginea de separare este mai mica

7. Cum afecteaza distanta dintre punctele exemple pozitive si punctele exemple negative ponderile vectorilor suport?

- a. Cu cat sunt mai departe unele de altele cu atat ponderile sunt mai mari
- b. Distanța nu afecteaza ponderile
- c. **Cu cat sunt mai departe unele de altele cu atat ponderile sunt mai mici**

8. Cea mai buna margine de separare este cea mai lata. Pentru a maximiza aceasta margine trebuie:

- a. Sa se maximizeze functia Lagrange in raport cu w si b
- b. **Sa se maximizeze functia Lagrange in raport cu α**
- c. Sa se maximizeze w si b
- d. Sa se minimizeze functia Lagrange in raport cu α

9. O buna practica pentru a evita overfitting-ul este:

- a. Se foloseste o functie de optimizare mai buna
- b. **Se utilizeaza un parametru pentru a controla marginea soft**
- c. Nu exista buna practica
- d. Se elimina aleator 50% din exemplele de antrenare

10. Vectorii suport sunt punctele (corespunzatoare exemplelor de invatare)

- a. aflate in exteriorul marginii de separare a exemplelor
- b. aflate in interiorul marginii de separare a exemplelor
- c. corespund numai exemplelor pozitive
- d. **aflate pe extremitatea marginii de separare a exemplelor**
- e. corespund numai exemplelor negative

Curs 5 - Reinforcement Learning

1. Care este diferenta intre un proces de decizie Markov (MDP) si un sistem Markov cu recompensa (MS)

- a. **MDP implica alegerea unei actiuni de catre agent pe cand MS nu**
- b. Intr-un MDP recompensa este atenuata pe masura functionarii agentului pe cand intr-un MS aceasta nu se atenuaza
- c. In MDP agentul se deplaseaza intr-un mediu nedeterminist pe cand in MS mediul este determinist
- d. Nu este nici o diferenta

2. Care este diferenta principala intre un proces de decizie Markov (MDP) si un agent RL? Bifati raspunsul corect.


- a. In MDP agentul calculeaza utilitatile pe cand in RL agentul calculeaza recompense
- b. In MDP mediul este determinist pe cand in RL mediul este nedeterminist
- c. In MDP agentul are un model complet al mediului pe cand in RL agentul nu are un astfel de model**

3. Ce valori se determina prin algoritmul de iterare a valorii?

- a. actiunile agentului
- b. utilitatea starilor**
- c. modelul de tranzitie al mediului
- d. recompensa starilor

4. Se considera urmatorul sistem Markov cu factor de atenuare de $1/2$

Care sunt valorile utilitatilor starilor (U_a , U_b , U_c) folosind Value Iteration (iterarea valorii) la momentul $t=2$ (functionarea incepe la momentul $t=1$)?



/mod/quiz/review.php?attempt=32565;

Learning: Attempt review

- a. (2 , 0 , 2)
- b. (0 , 0 , 0)
- c. (2.5 , 1 , 2) -> de ce nu (2.5 , 1 , 3)?**
- d. (3 , 1, 2.5)
- e. (2.5 , 1.5 , 1.5)

5. Un agent RL parcurge urmatoarea secventa de stari


$S_1(R=1) \rightarrow S_2(R=0) \rightarrow S_3(R=2) \rightarrow S_1(R=1) \rightarrow S_3(R=2)$

si obtine pentru fiecare stare recompensele indicate in paranteza. Factorul de atenuare este $1/2$. Care este utilitatea estimata de agent pentru starea S_1 in urma acestei explorari a mediului?

- a. $15/8$ -> de ce nu $14/8$?**
- b. $7/4$
- c. $1/2$
- d. $11/4$
- e. $15/4$

6. Fie urmatorul grid in mediu nedeterminist in care agentul se poate misca SUS, JOS, STANGA, DREAPTA. In urma unei miscari agentul ajunge in pozitia dorita cu o probabilitate de 0.8 si cu probabilitati de 0.1, 0.1 in pozitii aflate cu 90 de grade la stanga, respectiv dreapta pozitiei dorite. Daca deplasarea nu se poate face intr-o pozitie agentul ramane in acea pozitie cu probabilitatea 0.8, si 0.1, 0.1 se deplaseaza 90 de grade stanga, dreapta fata de pozitia dorita.

Considerand ca agentul porneste din starea START si urmeaza cea mai scurta secventa de actiuni care il duce in starea GOAL, care este probabilitatea de a ajunge in starea GOAL?



- a. 0.32776
- b. 0.0008
- c. 0.32768 -> asta e marcat ca fiind gresit in testul vechi
- d. 0.4096

7. Care din urmatoarele ecuatii corespunde modelului orizontului infinit atenuat?

- ☒ a. $U(S_t) = (\sum_{i=0, \infty} \delta^i R(S_t))$ ✓
- ☐ b. $U(S_t) = (\sum_{i=0, \infty} R(S_t))$
- ☐ c. $U(S_t) = (\sum_{i=0, n} R(S_t))$

Curs 6 - RL

1. Care din urmatoarele afirmatii este adevarata?

- a. **In Q-learning, politica este greedy, in SARSA politica nu este greedy**
- b. In Q-learning, politica nu este greedy, in SARSA politica nu este greedy
- c. In Q-learning, politica nu este greedy, in SARSA politica este greedy

2. Metoda Temporal Diference Learning este o metoda:

- a. Model free si agent activ
- b. Model based si agent activ
- c. **Model free si agent pasiv**
- d. Model based si agent pasiv

3. Fie urmatorul grid in care agentul parcurge episoade de la start la finish. Daca ajunge la finish se pozitioneaza din nou la start si reia episodul. In casuta finish recompensa este +10, in toate celelalte stari recompensa este -1. Modelul mediului este determinist.

Agentul se deplaseaza in grid up, down, left, right. Agentul incepe la start si la un moment dat are valorile Q din tabela de mai jos. Agentul are o politica greedy si un factor de atenuare de 0.9

4	5	finish 6
start	-	-

<mod/quiz/review.php?attempt=49488&cmid=1645>

iew

1	2	3
---	---	---

Q(1,up)=4			Q(1,right)=3
Q(2,up)=6		Q(2,left)=3	Q(2,right)=8
Q(3,up)=9		Q(3,left)=7	
	Q(4,down)=2		Q(4,right)=5
	Q(5,down)=6	Q(5,left)=5	Q(5,right)=8

Care este urmatoarea valoare a lui Q(3,left)?

- a. 6
- b. 0.9
- c. 1
- d. 6.2**
- e. 7. 2

4. In Q learning agentul

- a. invata si are un model al mediului

b. invata si nu are un model al mediului

c. nu invata si are un model al mediului

Curs 7-8

1. O retea care clasifica exemplele in mai multe clase, iar in setul de antrenare un exemplu poate apartine mai multor clase, foloseste pe ultimul nivel functia de activare softmax.

True

False

2. Intr-o retea cu mai multe straturi ce functie de activare se foloseste in general pe ultimul nivel?

a. ReLU

b. sigmoid

c. Leaky ReLU

3. In functionarea perceptronului ponderile se actualizeaza

a. proportional cu o valoare aleatoare mica

b. proportional cu intrarile

c. proportional cu intrarile si cu diferenta intre iesirea retelei si iesirea dorita

4. De ce este utila vectorizarea in calculul retelelor neurale?

a. Asa se spune dar nu este sigur ca este adevarat

b. Se lucreaza mai bine cu vectori si matrici

c. Elimina cicluri for


5. In regresia logistica in retea pentru m exemple de ce dwk nu este indexat dupa exemple?

a. Valoarea lui dwk este cumulativa

b. Derivata unei singure valori este relevanta

c. Se calculeaza o singura derivata

6. Fie urmatoarea retea



Care sunt dimensiunile matricilor:

(i) $W[1]$, $b[1]$

(ii) $W[2]$, $b[2]$

(iii) $W[3]$, $b[3]$

In raspunsuri se specifica (numar linii, numar coloane) pt fiecare matrice

a. (i) (3,4) (4,1)

(ii) (3,1) (3,1)

(iii) (3,1) (1,1)

b. (i) (4,4) (3,4)

(ii) (3,4) (4,1)

(iii) (3,4) (4,1)

c. (i) **(4,4) , (4,1)**

(ii) (3,4), (3,1)

(iii) (1,3) (1,1)

7. Straturile mai adanci dintr-o retea calculeaza, in mod tipic,

a. caracteristici cu un grad de complexitate mai mare decat cele calculate in straturile mai putin adanci

b. caracteristici cu acelasi grad de complexitate ca cele calculate in straturile mai putin adanci

c. caracteristici cu un grad de complexitate mai mic decat cele calculate in straturile mai putin adanci

8. Care dintre urmatoarele formule este o implementare corecta a forward propagation pentru un nivel l , cu l intre 1 si L ?

- ☐ a. $Z^{[l]} = W^{[l-1]}A^{[l]} + b^{[l-1]}$
 $A^{[l]} = g^{[l]}(Z^{[l]})$
- ☒ b. $Z^{[l]} = W^{[l]}A^{[l-1]} + b^{[l]}$
 $A^{[l]} = g^{[l]}(Z^{[l]})$ ✓
- ☐ c. $Z^{[l]} = W^{[l]}A^{[l]} + b^{[l]}$
 $A^{[l+1]} = g^{[l]}(Z^{[l]})$
- ☐ d. $Z^{[l]} = W^{[l]}A^{[l]} + b^{[l]}$
 $A^{[l+1]} = g^{[l+1]}(Z^{[l]})$

9. O functie convexa are intotdeauna mai multe puncte de optiom locale

True

False

10. O retea de tip perceptron poate clasifica corect

a. orice date de intrare

b. date de intrare liniar separabile

c. date de intrare convexe

11. In backpropagation intr-o retea cu 2 straturi, fct sigmoid si vectorizare, $dZ[2]$ se calculeaza dupa formula

- ☐ a. $dA^{[1]} * g^{[1]'}(Z^{[1]})$
- ☐ b. $W^{[2]T} * g^{[1]'}(Z^{[1]})$
- ☐ c. $(1/m) \text{sum}_{\text{oriz}}(dZ^{[2]})$
- ☒ d. $A^{[2]} - Y$ ✓

Lucrare 1

1. In regresia logistica se folosesc:

- (a) Distributie Bernoulli
- (b) Distributie categoriala
- (c) Distributie binomiala
- (d) Distributie multinomiala

- a. (a) + (b) + (c)
- b. (b) + (c)
- c. (a) + (c)**
- d. (c) + (d)
- e. (a) + (b)

2. Care dintre următoarele reprezintă presupunerea simplificatoare pe baza căreia operează clasificatorul Naive Bayes?

- a. Distribuția din care sunt extrase datele este Bayesiană
- b. Exemplele unui set de date sunt considerate independente între ele
- c. Atributele unui exemplu sunt considerate independente între ele**
- d. Distribuția din care sunt extrase datele este Gaussiană

3. In cazul algoritmului C4.5 daca avem valori necunoscute pentru un atribut in anumie exemple de invatare trebuie sa

- a. atribuim acelui atribut valoarea cu cea mai mare frecventa din exemplele de invatare**
- b. atribuim acelui atribut valoarea cu cea mai mica frecventa din exemplele de invatare

4. Dorim sa rezolvam o problema de clasificare binara. Avem 2 clase, fiecare clasa cu 500 de exemple. Datele sunt liniar separabile.

Care este numarul maxim si minim de vectori suport?

- a. minim - 250, maxim - 500
- b. minim - 500, maxim - 500
- c. minim - 1000, maxim - 1000
- d. minim - 2, maxim - 1000**

5. Un agent se mișcă într-un mediu 3x3 cu următoarele recompense:

	1	2	3
1	0.5	0.5	0.5
2	-1	0.5	1
3	0.5	0.5	0.5

Agentul poate executa acțiunile A1 (se mută la stânga cu probabilitatea 0.8 sau se mută în celula de sus cu probabilitatea 0.2) și A2 (se mută la dreapta cu probabilitatea 0.6, se mută în celula de sus cu probabilitatea 0.2 sau se mută în celula de jos cu probabilitatea 0.2). Care este

utilitatea stării (2,2) dacă factorul de atenuare are valoarea 0.9 (calculați folosind ecuația Bellman pentru un pas)?

- a. 1.14
- b. 1.22**
- c. 0.72
- d. 0.5

$$U(s) = \max_a [R(s, a) + \text{atenuare} * \sum_{s'} T(s, a, s') * U(s')]$$

$$A1: U(2, 2) = 0.5 + 0.9 * (0.8 * (-1) + 0.2 * 0.5) = 0.5 - 0.9 * 0.7$$

$$A2: U(2, 2) = 0.5 + 0.9 * (0.6 * 1 + 0.2 * 0.5 + 0.2 * 0.5) = 0.5 + 0.9 * 0.8 = 1.22$$

6. Consideram urmatorul set de date perechi (x,y):

(0,12) (1,13.5) (2,15) (3,16.5) (4,18) (5,19.5) (6,21)

Care funcție descrie o regresie liniară pentru aceste date?

- a. $y=2.5x+12$
- b. $y=1.5x+12$**
- c. $y=12x+5$
- d. $y=0.6x+8$

$$y = ax + b$$


$$(0, 12) \Rightarrow b = 12$$

$$(1, 13.5) \Rightarrow a = 1.5$$


7. Fie un set de exemple cu N atribute boolene și clasificare în clasa și non-clasa. Câți arbori de decizie diferiți putem construi ?

- a. 2^{N+1}
- b. 2^N**
- c. 2^N
- d. $2N+1$


8. În urma antrenării unei regresii liniare multi variabile, se obține $h(x) = -6 + 1 \cdot x_1 + 0 \cdot x_2$. Care dintre figurile următoare este asociată acestei clasificări?




A.



B.




C.



D.

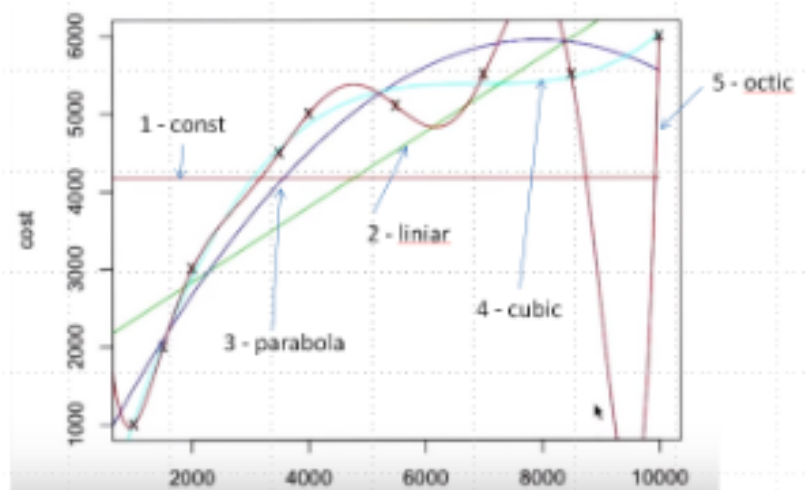
- a. C
- b. D
- c. A
- d. B

9. Dacă se elimina unul din punctele marcate cu rosu, hiperplanul de separare pentru un clasificator SVM se modifica?



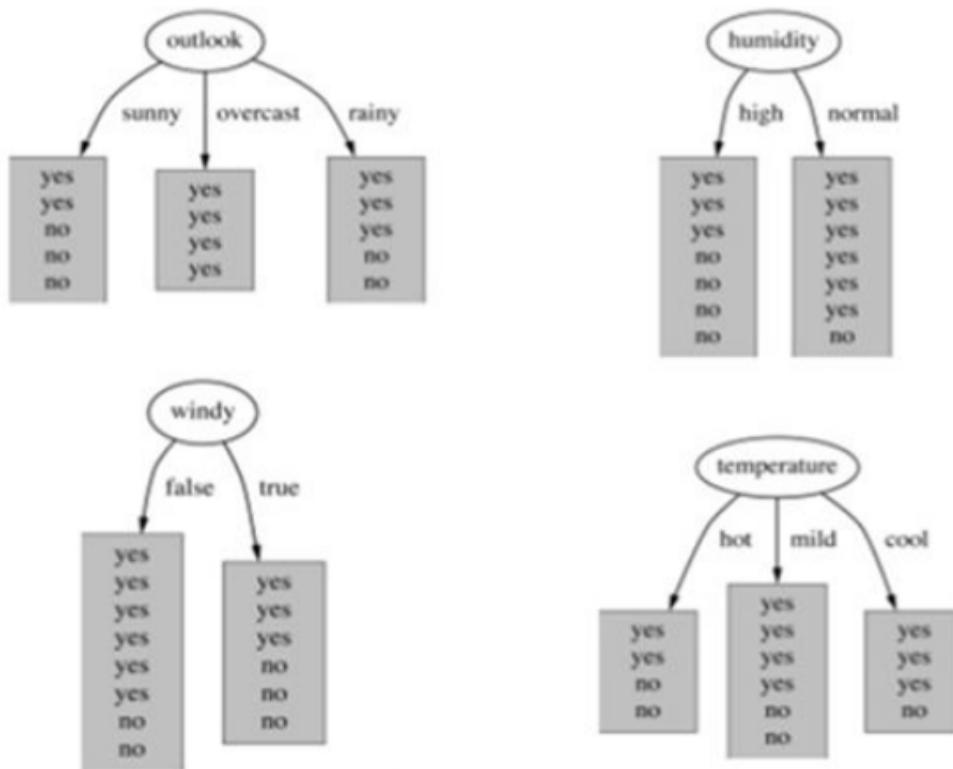
- a. Da
- b. Nu

10. Care curba trebuie aleasa pentru o buna predictie pe baza datelor existente in graficul urmator, folosind regresiei liniara?



- a. 2
- b. 3
- c. 1
- d. 4**
- e. 5

11. Se antrenează un arbore de decizie având “maximum information gain” (câștigul maxim informațional, bazat pe diferența de entropie) drept criteriu de selecție a atributelor. Considerând acest criteriu și următoarea situație de antrenare (cf. imaginii), care va fi atributul selectat pentru a “împărți” nodul curent:



a. Outlook

b. Temperature

c. Windy

d. Humidity

12. Ce tip de regresie ar trebui folosita pentru o problema in care dorim sa impartim un set de date in 2 categorii? (presupunem ca dorim sa antrenam un algoritm pentru care avem setul de date de antrenare)

a. Regresie liniara deoarece datele pot fi separate cu ajutorul unei drepte

b. Regresie logistica deoarece nu stim cum sa codificam "categoriile" in nume reale necesare regresiei liniare.

c. Regresia logistica deoarece foloseste functia logistica pentru a modela probabilitatea ca un punct din setul de date sa se gaseasca intr-o anumita clasa.

d. Regresie liniara deoarece cele 2 categorii (din setul de antrenare) pot fi etichetate cu 0 si 1.

In etapa de antrenare algoritmul va avea de gasit o dreapta care trece prin cele 2 puncte (0 si 1)

13. Care dintre urmatoarele reprezintă criterii de oprire pentru construcția arborelui de decizie cu algoritmul ID3. Alegeți opțiunile corecte dintre:

1. Toate exemplele din subset fac parte din aceeași clasă

2. Câștigul informațional ajunge să fie negativ

3. Nu mai există attribute valide cu care să creăm un nod test

4. Adâncimea maximă este atinsă


5. Câștigul informațional depășește un anumit prag

- a. 4 și 5
- b. 1
- c. 1, 3 și 4**
- d. 1 și 4
- e. 1, 2 și 3

14. Fie problema MDP. Se considera un grid cu 2 linii și 3 coloane, în care un agent se poate deplasa în direcțiile sus, jos, stanga, dreapta. Pentru fiecare stare recompensele sunt date în figura a). Deplasarea în grid va avea loc dacă agentul rămâne în grid. În caz contrar agentul va rămâne pe loc. Deplasarea în direcția aleasă se va face cu probabilitatea 0.8. Cu probabilitati 0.1, respectiv 0.1 agenul se va deplasa de-a lungul celor două diagonale care încadrează direcția de deplasare aleasă (ca în figura b).

S1 (R=0)	S2 (R=0)	S3 (R=10)
S4 (R=0)	S5 (R=0)	S6 (R= -5)

a)



b)

Dupa un numar de episoade utilitatile starilor sunt: $U(S1) = 5$, $U(S2) = 7$, $U(S3) = -3$, $U(S4) = 2$, $U(S5) = 4$, $U(S6) = -6$.

Care este utilitatea starii S5 pentru pasul urmator, avand factorul de atenuare = 0.9.

- a. 2.57
- b. 0.7
- c. 5.4
- d. 4
- e. 5.22**

$$U^k(S_i) = r_i + \text{atenuare} * \sum_j P_{ij} * U(S_j)^{(k-1)}$$

$$U(S5) = 0 + 0.9 * (0.8 * U(2) + 0.1 * U(S1) + 0.1 * U(S3)) = 0.9 * (0.8 * 7 + 0.1 * 5 + 0.1 * (-3)) = 0.9 * (5.6 + 0.5 - 0.3) = 0.9 * 5.8 = 5.22$$

15. Care este diferența principală între clasele bagging și boosting ale algoritmilor de tip ensemble?

- a. Clasificatorii metodelor de boosting sunt antrenați independent, în timp ce clasificatorii metodelor de bagging sunt antrenați iterativ
- b. Spre deosebire de boosting, metodele de bagging folosesc clasificatori slabi
- c. Spre deosebire de bagging, metodele de boosting folosesc clasificatori slabi
- d. Clasificatorii metodelor de bagging sunt antrenați independent, în timp ce clasificatorii metodelor de boosting sunt antrenați iterativ**

16. Datele de antrenare au erori deci ceea ce modelam nu este f ci $f + \epsilon$. Considerand posibilele surse de erori mentionate mai jos care credeti ca sunt cele mai importante in rezolvarea unei probleme prin regresie liniara?





- (a) Erori de la senzori
- (b) Erori de la o sursa malitioasa care introduce special aceste erori
- (c) Erori de transcriere (ale operatorului)
- (d) Influenta ale modelului care nu sunt luate in considerare

- a. (a) si (b)
- b. (a) si (c)
- c. (a) si (b) si (c) si (d)**
- d. (a) si (b) si (c)

17. Un set de date utilizat pentru învățare supervizată are o valoare mare a entropiei informaționale dacă:

- a. Foarte multe dintre exemple aparțin unui număr mic de clase, în timp ce restul de clase au un număr mic de exemple.
- b. Toate exemplele fac parte din aceeași clasă
- c. Numărul de exemple din fiecare clasă este relativ similar**


18. In urma antrenarii unei regresii, care figura corespunde aparitiei underfittingului?



- a. D**
- b. A
- c. B


d. C

19. Curbele de învățare ale unui arbore de decizie arată ca în figura de mai jos unde la fiecare pas de antrenare modelul vede mai mult din date. Ce afirmație este adevărată cu privire la regimul de performanță în care a ajuns modelul?



- a. Modelul este în regim optim
- b. Modelul este în regim de underfitting (sub-potrivire)
- c. Modelul este în regim de overfitting (supra-potrivire)**

20. Avem un set de date cu 2 clase -- punctele rosii si albastre. Punctele si posibile hiperplanuri de separare sunt plotate mai jos. Care ar fi cel mai bun hiperplan de separare (dintre cele 3: H1, H2, H3)?



- a. Nu exista un hiperplan de separare bun
- b. H2**
- c. H3
- d. H1

21. Pe un set de date cu attribute discrete se antrenează un arbore de decizie T prin algoritmul ID3, cu adancime maximă h. Pe același set de date se antrenează un model RandomForest M.

Modelul M folosește weak-learners (i.e. arborii de decizie care alcatuiesc Pădurea Aleatoare) identici cu T (i.e. același criteriu de alegere a atributelor, aceeași adâncime maximă h). Fiecare arbore din RandomForest este antrenat pe același set de date precum și folosind același set de attribute precum modelul T.

Modelul M astfel rezultat va avea:

- a. Aceeși acuratețe ca T**
- b. Acuratețe mai bună ca T
- c. Acuratețe mai mică decât T

22. Se dau următoarele două afirmații despre modelele de tip Gradient Boosted Trees.

- 1. Clasificatorii slabi (weak learners) sunt independenți unul de celălalt
- 2. Metoda Gradient Boosted Trees obține performanțe mai bune prin agregarea rezultatelor obținute de clasificatorii slabi (weak learners)

Care dintre cele două afirmații sunt adevărate:

- a. 2**
- b. 1 și 2
- c. 1
- d. Nici una

23. Regularizarea regresiiilor liniare și logistice presupune

- a. Selectarea acelor attribute ale datelor de intrare care sunt mai informative
- b. Transformarea spațiului de intrare într-unul mai complex
- c. Creșterea dimensiunii setului de antrenare prin adăugarea de noi exemple
- d. Adăugarea unui termen în funcția de cost care penalizează ponderile cu valori mari**

24. Care dintre următoarele afirmații este adevărată?

- (a) O funcție Kernel calculează un produs scalar într-un spațiu de dimensiune mai mare decât spațiul de intrare
- (b) Funcția Kernel este o funcție de similaritate

a. (a) și (b)

- b. (a)
- c. (b)
- d. Nici una

25. În urma antrenării unui SVM, sunt găsiți 3 vectori suport.

După ceva timp mai găsim încă un set de date cu aceleași caracteristici și clase ca setul folosit inițial (cele 2 seturi de date nu conțin intrări identice).

Antrenăm SVM-ul folosind reuniunea celor 2 seturi de date (setul reunit este încă liniar separabil), însă în urma procesului vectorii suport nu se schimbă.

Care afirmație este adevărată?

- a. performanța noului model este mai bună decât a celui antrenat doar pe setul inițial de date
- b. antrenarea folosind doar al doilea set de date ar avea ca rezultat vectori suport diferiți**

c. antrenarea SVM-ului folosind doar al doilea set de date va da mereu un hiperplan de separare diferit de cel initial

26. Procedura de cross-validation este folosită des pentru a găsi o valoare bună a hiperparametrilor unui model de învățare. În urma procedurii, se poate raporta o medie și o varianță a diferitelor modele (i.e. a instanțelor de model, pentru fiecare combinație de hiperparametrii).

Ce fel de modele vor fi preferate?

a. Modele cu medie mare și varianță mică

b. Modele cu medie mică și varianță mare

c. Modele cu medie mică și varianță mică

d. Modele cu medie mare și varianță mare

27. Se considera urmatorul set de exemple:

Nr	Culoara	Tip	Productia	Se
----	---------	-----	-----------	----

[nod/quiz/review.php?attempt=57365&cmid=17251](#)

review

Nr	Culoara	Tip	Productia	Se fura?
1	Rosu	Sport	Proprie	Da
2	Rosu	Sport	Proprie	Da
3	Rosu	Sport	Proprie	Da
4	Galben	Sport	Proprie	Da
5	Galben	Sport	Import	Da
6	Galben	SUV	Import	Nu
7	Galben	SUV	Import	Nu
8	Galben	SUV	Proprie	Da
9	Rosu	SUV	Import	Nu
10	Rosu	Sport	Import	Da

Aplicand algoritmul de invatare utilizand arbori de decizie, care este înalțimea minimă a arborelui?

a. 4

b. 1

c. 3

d. 2

28. Avem urmatoarea matrice de confuzie pentru o problema de clasificare binara (pe coloane sunt valorile reale, iar pe linii sunt valorile prezise).

Care afirmatie este adevarata?

Positive Negative

Positive	23	1
Negative	12	556

a. Accuracy=557/556

b. Recall=23/24

c. Precision=23/24

d. Accuracy=568/592

Precision = $TP / (TP + FP) = 23 / (23 + 1) = 23 / 24$

Recall = $TP / (TP + FN) = 23 / (23 + 12) = 23 / 35$

Accuracy = $(TP + TN) / (TP + FP + FN + TN) = (23 + 556) / (23 + 1 + 12 + 556) = 579 / 592$

29.

Care este transformarea $\phi(q)$ care corespunde Kernelului

$$K(a,b) = \phi^T(a) \phi(b) = a_1^2 b_1^2 + 2a_1 a_2 b_1 b_2 + a_2^2 b_2^2$$

☐ a. $[1 \quad q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 \quad \sqrt{2}q_2]$

☒ b. $[q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 q_2]$ ✓

☐ c. $[q_1 \quad q_2 \quad q_1^2 \quad q_2^2]$

☐ d. $[q_1 \quad q_2 \quad \sqrt{2}q_1^2 \quad \sqrt{2}q_2^2]$

☐ e. $[1 \quad q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 \quad \sqrt{2}q_2 \quad \sqrt{2}q_1 q_2]$

30. Intr-un arbore de decizie pentru clasificarea unor exemple care contin atribute cu valori continue, are sens sa repetam pe o anumita ramura a arborelui (cale de la radacina la o frunza) un acelasi atribut?

True

False

31. In cazul antrenarii regresiei liniare folosind urmatorul set de date (x: intrare, y: iesire), specificati care este valoarea $J(0, 1)$, unde $J(\theta, \theta)$ este functia de eroare pătratică pentru modelul de regresie liniară.

x	y
3	4
2	1
4	3
0	1

a. 1

b. 0.5

$$h_{\theta}(x) = 0 + 1 * x = x$$

$$J(\theta, \theta) = 1/2n * \sum_i (h(x_i) - y_i)^2 = 1/8 * (1 + 1 + 1 + 1) = 0.5$$

32. Care este ecuația care definește dreapta pe care se află vectorii suport ai clasei pozitive după determinarea marginii în algoritmul SVM? (w' reprezintă transpusul lui w)

a. $w' * x + b = -1$

b. $w' * x + b = 1$

c. $w' * x + b > 1$

d. $w' * x + b = 0$

33. Dorim să prezicem prețul unui apartament din zona Pipera. Pentru a face acest lucru ce putem folosi dintre:

a. Regresie logistică

b. Arbori de decizie

c. Regresie liniară sau logistică

d. Regresie liniară

e. Regresie liniară sau arbori de decizie

34. Care este avantajul folosirii algoritmului "iterarea valorilor" vs "iterarea politicilor"?

a. Necesită un efort computațional mai mic

b. Calculează o politică optimă mereu, lucru care nu e garantat de "Iterarea politicilor"

c. Poate fi aplicat în probleme în care nu se cunoaște dinamica mediului

d. Nu are avantaje

35. Ce presupune "Iama lui Occam" în contextul arborilor de decizie?

a. Un arbore corect de decizie trebuie să cuprindă toate atributele din setul de date

b. Nu există mai mulți arbori corecți pentru aceeași problemă

c. Nu se poate aplica principiul în contextul arborilor de decizie

d. Dacă sunt mai mulți arbori de decizie corecți, se preferă cel mai simplu

36. Care dintre următoarele sunt bune practici pentru reducerea overfitting-ului?

(a) Utilizarea unei funcții de cost cu 2 componente, care include un regulator pentru a penaliza complexitatea modelului

(b) Utilizarea unui optimizator bun pentru a reduce erorile pe datele de antrenare

- (c) Construirea unei structuri de subseturi de modele imbricate, antrenarea pe fiecare subset pornind de la cel mai mic, si oprirea cand eroarea de cross-validare incepe sa creasca
(d) Eliminarea aleatoare a 50% din datele de antrenare

- a. (c)
b. (a) si (c)
c. (a) si (b)
d. (b) si (c)
e. (a) si (b) si (c)

37. Folosim o regresie liniara pentru prezicerea prețului batoanelor de ciocolată “ROM” care a fost antrenat pe factorii economici din România. Modelul obține rezultate foarte bune, însă după ce este rulat peste 5 ani acesta va avea rezultatele diferite. Care poate fi cauza?

- a. Factorii economici se schimbă, iar modelul trebuie re-antrenat folosind date noi**
b. Trebuia să folosim o regresie logistică pentru a putea modela parametrul de timp
c. Modelul trebuia antrenat de la început cu mai multe date

38. Arborii de decizie construiți cu algoritmul ID3 prezintă robustețe crescută la „outliers”? Care dintre răspunsuri este cel mai plauzibil?

- a. Nu, pentru că vom obține valori negative pentru câștigul informațional în cazul lor.
b. Da, întrucât acest lucru este garantat prin calculul entropiei.
c. Da, pentru că unele attribute nu sunt luate în considerare.
d. Nu, pentru că ele (outliers) influențează sub-arborii generați ca fii ai unui nod test.

39. In urma antrenarii unui algoritm de invatare automata, observati ca acesta are o acuratete foarte buna pe setul de antrenare, inasa mica pe setul de testare.

Care poate fi motivul? Si cum am putea rezolva ? (presupunand ca avem un clasificator bazat pe arbori de decizie)

- a. Underfitting. Eliminam aleator un procent de date din setul de antrenare.
b. Underfitting. Putem adauga mai multe date in setul de testare.
c. Overfitting. Putem aplica pruning.
d. Overfitting. Aduugam mai multe attribute dupa care sa facem clasificarea

40. Ce se intampla daca se alege viteza de invatare (parametrul α pentru algoritmul de gradient descent) foarte mica, respectiv foarte mare?

- a. foarte mica - algoritmul de invatare ar putea sa converga prea lent spre o solutie foarte mare - algoritmul de invatare ar putea sa nu gaseasca solutia**

b. foarte mica - algoritmul de invatare ar putea sa converga repede spre o solutie.

foarte mare - algoritmul de invatare ar putea sa converga prea lent spre o solutie

c. Nu se intampla nimic, viteza de invatare poate fi oricat deoarece algoritmul mereu va converge spre solutie in acelasi timp.

d. Nu conteza viteza de invatare, deoarece formula de actualizare a parametrilor nu tine cont de aceasta.

Lucrare 2

Partea 1

1. Ce funcții de activare ați folosi într-o rețea pentru a putea obține valori negative în urma aplicării activării

- a. Logistică
- b. Tangentă hiperbolică**
- c. Leaky ReLU**
- d. ReLU

2. Fie următoarea rețea neuronală cu două intrări binare x_1 , x_2 și funcție de activare treaptă. Specificați care este funcția calculată.



- a. NOT AND
- b. XOR
- c. OR
- d. AND**

$$0, 0 \Rightarrow -30 + 0 * 20 + 0 * 20 = -30 < 0 \Rightarrow 0$$

$$0, 1 / 1, 0 \Rightarrow -30 + 0 * 20 + 1 * 20 = -10 < 0 \Rightarrow 0$$

$$1, 1 \Rightarrow -30 + 1 * 20 + 1 * 20 = 10 > 0 \Rightarrow 1$$

3. Câți parametri sunt într-o rețea care respectă structura de mai jos, antrenată pe setul de date MNIST (28x28x1):

2x

L0: Input

L1: Conv1(c=5, k=5, p=2, s=1)

L2: MaxPool(k=2, s=2)

L3: Conv2(c=5, k=3, p=1, s=1)

L4: AvgPool(k=2, s=2)

L5: ReLU

L6: Output

a. 12

b. 245

c. 170

d. 350

Layer cu parametri: Conv1, Conv2

Conv1: $1 * c1 * k1^2 = 125$

Conv2: $c1 * c2 * k2^2 = 225$

=> 350

4. Alegeți valoarea de adevăr pentru fiecare dintre următoarele propoziții:

i) Algoritmul Q-learning este de tipul on-policy

ii) Procesele de decizie Markov cu valori mici ale factorilor de atenuare accentuează recompensele pe termen scurt

a. Adevărat, adevărat

b. Adevărat, fals

c. Fals, fals

d. Fals, adevărat

5. Câți parametri trebuie să învețe un layer de Average Polling cu dimensiunea kernel-ului de 2 și pas de 2?


a. 2

b. 4

c. 3

d. 0

6. Cum interpretați figura de mai jos?



a. Rețeaua nu învață nicio caracteristică a datelor

b. Rețeaua are arhitectura potrivită pentru setul de date pe care este antrenată

c. Rețeaua intră în regim de overfit

7. În care din următoarele cazuri nu ați opta pentru utilizarea unui algoritm genetic:

a. Funcția de fitness este complexă și necesită mult efort computațional pentru a fi calculată

b. Nu există o soluție exactă pentru problemă

c. Problema conține atât variabile continue cât și discrete -> asta era pusă în test dar mi se pare futută

d. Problema are puține variabile care trebuie optimizate

8. Ce s-ar întâmpla într-o rețea neuronală artificială dacă am utiliza funcția de activare $y = 2x$, unde x este intrarea de pe un strat și y este ieșirea acestuia?

a. Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor.

b. Ar fi imposibil ca rețeaua să mai învețe să rezolve o problemă de clasificare sau regresie

c. Valorile de la output ar deveni foarte mari

d. Ponderile s-ar micșora considerabil.

9. Se considera o rețea neuronală cu două ieșiri care realizează o clasificare binară. Care dintre următoarele funcții de activare este recomandat a fi utilizată pentru stratul de ieșire.

a. ReLU

b. Leaky ReLU

c. sigmoid

10. Considerăm situația în care se antrenează un model folosind gradient descent, însă nu se ajunge la costul global minim. Care ar putea fi motivul?

a. Funcția de cost nu ține cont de regularizare.

b. Funcția de cost este un polinom de grad > 2 .

c. Funcția de cost nu este concavă.

d. Funcția de cost nu este convexă.

11. În algoritmul Q-Learning, care este efectul unei rate de învățare (learning rate) scăzute și a unui factor de atenuare (discount factor) ridicat:

a. Agentul prețuiește mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv

b. Agentul prețuiește mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

c. Agentul prețuiește mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv

d. Agentul prețuiește mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

12. Fie un strat de convoluție cu intrarea de dimensiune (7x7), filtru de dimensiune (3x3), stride = 1 (se ignora a treia dimensiune, nu exista padding). Specificati dimensiunea ieșirii stratului convolutional.

- a. **5x5**
- b. 7x7
- c. 3x3

$$H_{out} = (H_{in} + 2p - d * (k - 1) - 1) / s + 1 = ((7 - (3 - 1) - 1) / 1 + 1 = 5$$

13. Fie următoarea populație de 5 stringuri, unde fiecare string reprezintă codificarea în binar a unui număr natural. Considerând funcția de selecție $F = x / 100 + \#1(x)$, care sunt indivizii aleși în pasul de selecție, utilizând metoda atribuire fitness proporțională?

Observație: $\#1(x)$ întoarce numărul de "1" din reprezentarea în binar a lui x

Indivizi:

32: "0100000"

95: "1011111"

10: "0001010"

73: "1001001"

65: "1000001"

a. 32, 10, 95, 73, 65

b. 95, 95, 73

c. 95, 73

d. 65, 95, 73

$$32 \Rightarrow 32 / 100 + 1 = 1.32$$

$$95 \Rightarrow 95 / 100 + 6 = 6.95$$

$$10 \Rightarrow 10 / 100 + 2 = 2.1$$

$$73 \Rightarrow 73 / 100 + 3 = 3.73$$

$$65 \Rightarrow 65 / 100 + 2 = 2.65$$

$$\text{Avg} = (1.32 + 6.95 + 2.1 + 3.73 + 2.65) / 5 = 16.75 / 5 = 3.35 \Rightarrow \text{pastram 95 si 73}$$

$$95 \Rightarrow 6.95 / 3.35 = 2 \text{ ori}$$

$$73 \Rightarrow 3.73 / 3.35 = 1$$

14. Cum se poate preveni problema vanishing gradients în rețelele neurale adânci?

- a. Prin creșterea numărului de parametri în straturi
- b. Prin introducerea de conexiuni reziduale între straturi**
- c. Prin adăugarea mai multor straturi convoluționale în rețea

15. Straturile de tip Average Pool sunt utilizate în arhitecturile de rețele neuronale artificiale adânci cu scopul de a

- a. Întări corelațiile care se întâmplă la nivel local.
- b. Reduce dimensiunea activărilor de la ieșirea unui strat înainte de a fi trimis stratului următor**
- c. Îmbunătățește calitatea informației care este propagată prin rețea.

d. Reduce zgomotul din rețea prin efectuarea mediei activărilor

16. În formula de actualizare a parametrilor unei rețele folosind gradient descent cu momentum, ce se întâmplă când gamma are valoarea 1 și eta are valoarea 0?

Momentum based Gradient Descent Update Rule

$$v_t = \gamma * v_{t-1} + \eta \nabla w_t$$
$$w_{t+1} = w_t - v_t$$

a. Rețeaua nu învață valorile optime ale parametrilor

b. Rețeaua învață foarte greu valorile optime ale parametrilor

c. Rețeaua învață mai repede valorile optime ale parametrilor

d. Formula devine echivalentă cu formula pentru SGD simplu

17. Care din următoarele stringuri nu este un rezultat posibil care se poate obține pentru individul "1934523107" după o operație de crossover, cu crossover point la 70% din lungimea individului?

a. 1984528107

b. 1034523207

c. 1934523813

d. 1934523107

1934523---107

18. Considerăm situația în care se antrenează un model folosind gradient descent. La un moment dat derivata funcției de cost ajunge să fie 0, însă nu avem nicio informație despre funcția de cost. Ce se poate spune cu siguranță?

a. Funcția a ajuns într-un minim sau maxim global.

b. A fost găsit un minim local.

c. A fost găsit un maxim global.

d. Nici o afirmație nu este adevărată.

19. Care dintre următoarele metode ajută la reducerea procesului de “overfitting”?

a. Utilizăm un set aleator (redus) de feature-uri din setul de antrenare.

b. Folosim un model cu mai mulți parametri.

c. Utilizăm metode de regularizare.

d. Reducem rata de învățare pe parcursul antrenării.

20. Care dintre următoarele condiții au ca efect obținerea aceluiași rezultat pentru algoritmi Q-Learning și SARSA în privința valorilor Q estimate?

1. Un mediu determinist

2. Un mediu nedeterminist, dar unde tranziția între stări se face complet uniform

3. O metodă de explorare a acțiunilor într-o stare care este lăcomă (greedy)

4. O rată de învățare egală cu zero

a. 3

b. 1, 3 și 4

c. 3 și 4

d. 4

e. 1 și 4

f. 2, 3 și 4

21. Care dintre următoarele procedee au ca efect reducerea variabilității valorilor de actualizare a ponderilor (Δw) în timpul procesului de stochastic gradient descent (SGD)?

1. Reducerea dimensiunii batch-urilor

2. Reducerea ratei de învățare

3. Creșterea dimensiunii batch-urilor

4. Creșterea ratei de învățare

a. 1 și 4

b. 4

c. 3 și 4

d. 1

e. 3

f. 2 și 3

g. 1 și 2

h. 2

22. Cum se reprezintă o politică?

a. O funcție pentru asocieri stare - acțiune

b. O funcție pentru asocieri stare - utilitate

c. O funcție care asociază valori (utilități) pentru fiecare pereche (stare, acțiune)

d. O listă cu acțiuni

23. În cazul unui algoritm genetic cu o populație formată dintr-un singur individ, se pot obține indivizi noi în populație folosind:

a. Recombinare urmată de mutație

b. Numai recombinație

24. MSE (Mean Squared Error) Care dintre următoarele funcții de eroare ați utiliza pentru o rețea pe care o antrenați într-o problemă de regresie?


a. Multi-Class Cross-Entropy

b. Negative Log Likelihood

c. Binary Cross-Entropy

d. MSE (Mean Squared Error)

25. Pentru următoarea rețea SOM, care are 5 noduri (A - E) și 3 intrări. Rețeaua clasifică avioane pe baza valorilor celor trei intrări: 1 (dimensiune avion), 2 (număr maxim pasageri), 3 (viteza maximă posibilă). Care este numărul maxim de tipuri de avioane ce pot fi clasificate?



a. 4

b. 2

c. 5

d. 3

26. Q-Learning este o instanță a TD(0).

True

False

Partea 2

1. Q-learning

Se da următoarea reprezentare a valorilor Q pentru fiecare din acțiunile $A = \{\text{sus, jos, stânga, dreapta}\}$, asociate unei stări marcate prin simbolul \diamond în tabelul de mai jos.


Care va fi distribuția peste setul de acțiuni A atunci când agentul folosește metoda ϵ -greedy (cu $\epsilon = 0.1$), și atunci când folosește o metodă de explorare ponderată (unde convertirea la probabilități se face prin operație de mediere ponderată a valorilor Q)?

Exprimați răspunsul ca tuplu de patru valori în ordinea (sus, jos, stanga, dreapta), cu precizie la a treiazecimală, prin rotunjire în jos.

13.4
2.4 ♦ 2.4
12.1

2. Retele neurale

Se da următoarea problemă de clasificare binară.



Se presupune cunoscut faptul că un clasificator liniar (e.g. regresie logistică, SVM cu kernel liniar), NU poate clasifica în mod corect setul de antrenare reprezentat mai sus.

Considerați o rețea neurală de tip feed-forward configurată în modul următor:

Input -> [strat liniar] -> activare liniara -> [strat liniar] -> activare liniara -> [strat liniar] -> activare logistică -> Output

Este această configurație de rețea capabilă să învețe o clasificare 100% corectă a problemei date? Justificați.

Raspuns de anul trecut (1/1):

Stratul si functia de activare sunt liniare, deci rezultatele vor fi doar combinatii liniare ale intrarilor, care stim deja ca nu pot fi clasificate corect. Nu este. Pentru a clasifica corect, ar trebui sa introducem o functie non-liniara.

Raspuns dintr-un doc:

Nu, pentru a rezolva problema este nevoie de un clasificator non-liniar care sa separe corecte datele de intrarea.

3. AG

Un algoritm genetic folosește cromozomi de forma $x = abcdefgh$, cu o lungime fixă de 8 gene (de la a la h). Fiecare genă constă într-un număr din intervalul $[0 \dots 9]$. Funcția de fitness a unui individ x se calculează prin $f(x) = (a+b) - (c+d) + (e+f) - (g+h)$.

Fie populația de indivizi dată prin:

O1: 8 7 1 2 3 5 3 2

O2: 6 5 9 2 1 2 3 2

O3: 2 7 1 2 6 2 0 1
O4: 5 8 3 4 3 9 4 2

Care este individul cu fitness maximal si care este aceasta? Specificati raspunsul sub forma<nume_individ>:<valoare fitness>.

O1:15

$$\begin{aligned}f(O1) &= (8 + 7) - (1 + 2) + (3 + 5) - (3 + 2) = 15 - 3 + 8 - 5 = 15 \\f(O2) &= (6 + 5) - (9 + 2) + (1 + 2) - (3 + 2) = 11 - 11 + 3 - 5 = -2 \\f(O3) &= (2 + 7) - (1 + 2) + (6 + 2) - (0 + 1) = 9 - 3 + 8 - 1 = 13 \\f(O4) &= (5 + 8) - (3 + 4) + (3 + 9) - (4 + 2) = 13 - 7 + 12 - 6 = 12 \\f(\text{old_pop}) &= 15 - 2 + 13 + 12 = 38\end{aligned}$$

Încrucișați indivizii O1 și O4 prin 2-point crossover, cu tăiere după genele b și f.
Scrieți indivizii rezultanți (Onew3 și Onew4) sub forma indicată în populație.

Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 2

Ox: **a b c d e f g h**

O1: **8 7 1 2 3 5 3 2**

O4: **5 8 3 4 3 9 4 2**

$$\Rightarrow 8\ 7 + 3\ 4\ 3\ 9 + 3\ 2 = \mathbf{8\ 7\ 3\ 4\ 3\ 9\ 3\ 2}$$

$$5\ 8 + 1\ 2\ 3\ 5 + 4\ 2 = \mathbf{5\ 8\ 1\ 2\ 3\ 5\ 4\ 2}$$

Care este fitness-ul populației noi formate din (Onew1,Onew2, Onew3 și Onew4)? Este el mai mare decâtfitness-ul populației anterioare?

f(new_pop)=55, DA

$$\begin{aligned}f(\text{Onew1}) &= (8 + 7) - (1 + 2) + (6 + 2) - (0 + 1) = 19 \\f(\text{Onew2}) &= (2 + 7) - (1 + 2) + (3 + 5) - (3 + 2) = 9 \\f(\text{Onew3}) &= (8 + 7) - (3 + 4) + (3 + 9) - (3 + 2) = 15 - 7 + 12 - 5 = 15 \\f(\text{Onew4}) &= (5 + 8) - (1 + 2) + (3 + 5) - (4 + 2) = 13 - 3 + 8 - 6 = 12 \\f(\text{new_pop}) &= 19 + 9 + 15 + 12 = 55\end{aligned}$$

Care este valoarea maximală de fitness care poate fi atinsă de un individ prin funcția f?

$$F_{\text{max}} = (9 + 9) - (0 + 0) + (9 + 9) - (0 + 0) = \mathbf{36}$$

Incrucișați primii doi indivizi în ordinea fitness-ului prin crossover single point (recombinare binară cu punct de recombinare la 50% din lungimea cromozomului).

Scrieți indivizii rezultanți (Onew1 și Onew2) sub forma indicată în populație (e.g. Onew1: a b c d e f g h).

Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2

O1: **8 7 1 2 3 5 3 2**

O3: **2 7 1 2 6 2 0 1**

4. Q-learning

Se considera stările (s_1, s_2, s_3, s_4); în fiecare stare poate fi executată una din acțiunile (a_1, a_2, a_3). După aplicarea algoritmului Q-learning, pentru un număr de episoade, se obțin următoarele valorile $Q(\text{stare}, \text{acțiune})$:

	$s = s_1$	$s = s_2$	$s = s_3$	$s = s_4$
$a = a_1$	0.1	0.2	0.3	0.4
$a = a_2$	0.5	0.6	0.7	0.8
$a = a_3$	0.9	1.0	1.1	1.2


În continuare, agentul porneste din starea s_3 și execută acțiunea a_1 . El va primi recompensa 1 și va trece în starea s_2 . În această stare el va alege să execute acțiunea a_2 , prin care va ajunge în starea s_4 , iar recompensa primită va fi 0. Calculați modificările pentru $Q(\text{stare}, \text{acțiune})$ prin executarea acestor acțiuni ($\alpha = 0.2, \delta = 0.9$).

Răspuns (1/1):

$$Q(s_3, a_1) = 0.3 + 0.2 * (1 + 0.9 * 1 - 0.3) = 0.62 \quad Q(s_2, a_2) = 0.6 + 0.2 * (1 + 0.9 * 1.2 - 0.6) = 0.896$$

5. SOM

Pentru următoarea rețea SOM cu 6 noduri (A-F) și 2 intrări (x_1, x_2 - intrările nu sunt specificate în figura) ponderile asociate fiecărui nod sunt w_1 și w_2 . Se considera valoarea (2, -4) aplicată pe intrări. Se utilizează distanța euclidiană, specificați care sunt nodurile pentru care se vor actualiza ponderile (se considera o vecinătate cu rază = 1).



Node	A	B	C	D	E	F
w_1	-1	0	3	-2	3	4
w_2	2	4	-2	-3	2	-1

Răspuns (1/1):

Punctul $x, y = (2, -4)$

$$D(x, A) = (w_1 - x)^2 + (w_2 - y)^2 = 3^2 + 6^2 = 9 + 36 = 45$$

$$D(x, B) = 2^2 + 8^2 = 4 + 64 = 68$$

$$D(x, C) = 1^2 + 2^2 = 5$$

$$D(x, D) = 4^2 + 1^2 = 17$$

$$D(x, E) = 1^2 + 6^2 = 37$$

$$D(x, F) = 2^2 + 3^2 = 13$$

Se observa ca cel mai apropiat punct este C. $R = 1$, deci se vor actualiza sunt nodurile cu distanta < 1 fata de C, adica B si D, si nodul C

6. Retele convolutive

Se da următoarea arhitectură a unei rețele convoluționale:

Input(64 x 64 x 3) -> Conv1(c=8, k=5, p=0, s=1) -> ReLU1 -> Conv2(c=16, k=3, p=1, s=1) ->

Pool2(k=2, s=2) -> ReLU2 -> Conv3(c=32, k=3, p=0, s=1) -> ReLU3 -> Output,

unde c - numar de canale, k - dimensiune kernel, p = padding, s = stride, iar inputul este dat in formatul H x W x C (height, width, channels).

Care este numărul total de ponderi aferente stratului convolutional Conv2

1152

$$c1 * c2 * k^2 = 8 * 16 * 3^2 = 1152$$

Care este dimensiunea pentru outputul final, exprimata in format (H, W, C)

(28, 28, 32)

Input -> Conv1 -> Conv2 -> Pool2 -> Conv3

(64, 64, 3) -> (60, 60, 8) -> (60, 60, 16) -> (30, 30, 16) -> (28, 28, 32)

$$Hc1 = (Hc0 + 2p1 - d1 * (k1 - 1) - 1) / s1 + 1 = 64 - (5 - 1) = 60$$

$$Hc2 = (Hc1 + 2p2 - d2 * (k2 - 1) - 1) / s2 + 1 = 60 + 2 - (3 - 1) = 60$$

$$Hp2 = (Hc2 + 2pp2 - dp2 * (kp2 - 1) - 1) / sp2 + 1 = (60 - (2 - 1) - 1) / 2 + 1 = 58 / 2 + 1 = 30$$

$$Hc3 = (Hp2 + 2p3 - d3 * (k3 - 1) - 1) / s3 + 1 = 30 - (3 - 1) = 28$$

7. AG

Fie un set de 8 indivizi avand următoarele valori de fitness asociate

#Ind	1	2	3	4	5	6	7	8
Fit.	17	5	13	15	12	8	6	24

Cei 4 indivizi alesi conform unei proceduri de selectie universala stohastica (unde primul pointer are valoarea 0.1) sunt:

1,3,6,8

$$NPointer = 4$$

$$\text{Distanța între pointeri} = 1 / NPointer = 1 / 4 = 0.25$$

$$P1 = 0.1 \Rightarrow 8$$

$$P2 = 0.35 \Rightarrow 1$$

$$P3 = 0.6 \Rightarrow 3$$

$$P4 = 0.85 \Rightarrow 6$$

$$F_{\text{tot}} = 17 + 5 + 13 + 15 + 12 + 8 + 6 + 24 = 100$$

8: [0, 0.24)
1: [0.24, 0.41)
4: [0.41, 0.56)
3: [0.56, 0.69)
5: [0.69, 0.81)
6: [0.81, 0.89)
7: [0.89, 0.95)
5: [0.95, 1)

Cei 4 indivizi alesi conform unei proceduri de selectie pe baza de ruleta cu extragerile aleatoare (0.1, 0.7, 0.5, 0.3) sunt:

1,4,5,8

$P1 = 0.1 \Rightarrow 8$

$P2 = 0.7 \Rightarrow 5$

$P3 = 0.5 \Rightarrow 4$

$P4 = 0.3 \Rightarrow 1$

$F_{tot} = 17 + 5 + 13 + 15 + 12 + 8 + 6 + 24 = 100$

8: [0, 0.24)
1: [0.24, 0.41)
4: [0.41, 0.56)
3: [0.56, 0.69)
5: [0.69, 0.81)
6: [0.81, 0.89)
7: [0.89, 0.95)
5: [0.95, 1)

Alte docuri

https://docs.google.com/document/d/1-MWB_t14EUTrWrE5K0m6CzzgFSuIY154wlqnf_UVzrs/e/dit

1. invatarea pac. ce inseamna o ipoteza de invatare aproximativ corect, ce inseamna o ipoteza de invatare probabil aproximativ corecta. Explicati semnificatia celor 2 notiuni pentru invatarea automata si explicati diferentele intre acestea.

2. Intr-o retea de tip SOM(Self organizing maps) , nu numai unitatea castigatoare este mutata catre exemplu dar si unitatile din vecinatatea acesteia. De ce este acest aspect important in metoda de invatare?

3. Sa se proiecteze o retea neurala care spune daca suma a 2 cifre($0 \leq \text{cifra} \leq 7$) este mai mare ca 8.

R:

$x_1 \text{ ---}(w_1 = 1)\text{---> |}$
 $\text{ |---> ** } O = 9 \text{ ** -----> ** } y = f(w_1 * x_1 + w_2 * x_2 - O) \text{ **}$
 $x_2 \text{ ---}(w_2 = 1)\text{---> |}$

$f(x) = 1, \text{ pentru } x > 0$
 $0, \text{ altfel}$


O este "theta", $x_1/2$ sunt intrari, ce este intre "***" sunt neuroni

Î: Theta nu ar trebui sa fie 8 conform cerintei?

R: Pai zice > 8 , nu ≥ 8 .

Î: Domeniul cifrei conteaza la ceva?

R: DA / daca era binar



4. Care e conditia de convergenta la algoritmul de invatare al perceptronului? Dar la Hopfield?

R: In cazul perceptronului, invatarea se opreste atunci cand eroare este 0, cand diferenta dintre iesirea oferita de perceptron si valorile dorite pentru diverse intrari sunt identice. (Cand toate exemplele sunt clasificate corect)

Reteaua Hopfield converge atunci cand se ajunge intr-un minim local energetic, cand niciun neuron nu doreste sa isi schimbe starea. *Adica atunci cand iesirea fiecarui neuron la momentul $t+1$ este aceeaasi ca cea la momentul t , nu? DA :)*

(liniar separabilitatea)(adica se updateaza weights-urile pana cand se ajunge la o clasificare corecta sau numarul iteratiei a ajuns la o valoare maxima?) Dar la Hopfield? ($w_{ij}=w_{ji}$) (Conditia de convergenta la Hopfield nu este cumva ca sablonul la momentul viitor ($t+1$) sa fie acelasi ca sablonul la momentul t ? curs 4, pag 28)

Cred ca intrebarea se refera cand stim ca ar converge dinainte de rulare. In acest caz, la perceptron sigur e corecta liniar separabilitatea.

Atunci la Hopfield inseamna ca el converge daca $M < 0.138 * N$? (curs 4, pag 30)
M=nr de clase, N=numarul de input-uri

Stai sa vad ce sunt M si N si wtf. CONCLUZIE: cred ca da

La Hopfield converge daca functia de energie e functie Lyapunov (iar Hopfield a demonstrat ca asta se intampla daca $w_{ij} = 0$ oricare i si $w_{ij} = w_{ji}$ oricare i, j)

5. Care este legatura intre stabilizarea unei retele Hopfield si un proces de cautare?

R: Pentru a cauta un anumit sablon intr-o retea neurala Hopfield deja antrenata, se initializeaza starea neuronilor conform sablonului dorit si se lasa ca reteaua sa se stabilizeze. Starea finala a neuronilor este sablonul rezultat in urma cautarii.

Pentru regasirea unui sablon, este suficient sa se specifice numai o parte a acestuia, iar reteaua gaseste automat intreg sablonul.

Totusi, una dintre limitarile majore ale alg. hopfield este cazul in care un sablon are mai multe valori identice cu un alt sablon in exemple, caz in care sablonul poate fi instabil = reteaua converge spre o stare diferita de cea asociata sablonului.

Procesul de relaxare paralela a retelei pentru a atinge o stare stabila poate fi vazut ca un proces de cautare in spatiul starilor stabile ale retelei. O configuratie de intrare va forta reteaua sa ajunga intr-o stare stabila ce reprezinta un minim local, starea stabila cea mai apropiata.

6. Care este conditia de convergenta in cazul unei retele backpropagation ?

R: Eroarea sa fie 0.

Aici cred ca nu e bine. Se ajunge la convergenta cand eroarea nu se mai schimba (gradientii la iesire devin 0). => Mult mai bine așa; dacă ar fi eroarea 0, se poate să nu se ajungă niciodată în acel punct și nu se va mai opri. :)

perceptron: set de invatare sa fie liniar separabil;

backpropagation: ? (eroarea cu care se intoarce sa fie minima?)

7. Care sunt aplicatiile cele **mai importante** ale unei retele Hopfield si pe ce principii se bazeaza acestea ?

R: Recunoasterea de **patternuri**, problema comis voiajorului (*sa fim seriosi, problema comis voiajorului nu se rezolva cu Hopfield like*). Suntem, dar si decana a fost cand a bagat problema in **curs** :P (realizeaza o aproximare, in cel mai bun caz :)))

(Cele doua aplicatii ale retelei **Hopfield** au fost luate dintr-un paper.)

Aplicatia cea mai importanta a unei retele Hopfield este intelegerea memoriei umane

(http://en.wikipedia.org/wiki/Hopfield_network).

Aplicații unde este căutată soluția de cost minim.

8. Retea, ponderi, functie de activare **pentru:**

x1	x2	y
1	0	1

0	1	1
0	0	1
1	1	0

=> NAND

$$h = x_1 * w_1 + x_2 * w_2 - O$$

$$f(h) = y$$

$$f(w_1 - O) = 1$$

$$f(w_2 - O) = 1$$

$$f(-O) = 1$$

$$f(w_1 + w_2 - O) = 0$$

$$f(x) = 1, x > 0 \text{ altfel } 0$$

$$w_1 - O > 0$$

$$w_2 - O > 0$$

$$0 > O$$

$$w_1 + w_2 - O < 0$$

=> 3 valori care merg sunt $w_1 = -2$, $w_2 = -2$ si $O = -3$


R: $w_1/2 = 1$;

$$f(x_1, x_2) = (w_1 x_1 + w_2 x_2) < 2 \quad ??$$

Asta nu e nand? mie asa mi se pare. Si ar fi $w_1 = 1$; $w_2 = -1.5$ si teta -2

Un singur perceptron cu 2 intrari. $w_1 = -2$; $w_2 = -2$; teta $= -3$; $f(x) = 1$ daca $x > \text{teta}$ si invers $f_x = 0$;

9. Sa se construiasca o retea neurala cu 3 intrari si 3 iesiri, care sa afle maximul intrarilor.



Explicatii:

- neuronul a cu $w_{x1}=1$ si $w_{x2}=-1$ si $teta=0$ are iesirea 1 daca $x1 > x2$ si -1 altfel
- neuronul b cu $w_{x2}=-1$ si $w_{x3}=1$ si $teta=0$ are iesirea 1 daca $x3 > x2$ si -1 altfel
- neuronul c cu $w_{x1}=1$ si $w_{x3}=-1$ si $teta=0$ are iesirea 1 daca $x1 > x3$ si -1 altfel
- neuronul d cu $w_a=1$ si $w_c=1$ si $teta=2$ are functia de AND(a, c), deci e activat

cand $max=x1$

-neuronul e cu $w_a=-1$ si $w_b=-1$ si $teta=2$ are functia de AND($\sim a$, $\sim b$), deci e activat cand $max=x2$

-neuronul f cu $w_b=1$ si $w_c=-1$ si $teta=2$ are functia de AND(b , $\sim c$), deci e activat cand $max=x3$

Exemplu: input: $X=[0.3 \ 0.5, -0.2]$. Output: $Y=[0, 1, 0]$

10. Care este numarul de neuroni necesari pentru o retea cu n noduri de intrare si n noduri de iesire ?

R: n? cel putin n

Minim n ca sa fie n iesiri diferite... Confirmare, pls?

11. Indicati o retea neurala care sa poate sa reproduca litera C.

R: perceptron / hopfield.

Cursul 5, slide-ul 15 contine neuronul care se leaga la pixeli. In matrice sunt puse ponderile, iar $teta$ = nr min de pixeli care trebuie sa faca match ca retea sa intoarca un raspuns pozitiv.

Număr de neuroni și dispunerea lor

- Hopfield

- Pe straturi

Apoi pentru fiecare neuron W-ul asociat.

Ex: Perceptron. Presupunem ca avem 9 pixeli:

xxx

x00

Xxx

Intrarile sunt fiecare pixel + o intrare legata la un -1 (adica omega din exemplul de mai jos)

Pentru pixelii care sunt 0 -> ponderea e -100

Pentru pixelii care sunt 1 -> ponderea e 1

Functia de activare este functia treapta ($0 \text{ if } x < 0 \text{ else } 1$)

Ca sa dea 1 doar daca pixelii sunt aprinsi in forma de C, punem la legatura cu 1 -6

Astfel:

-Un pixel aprins gresit -> pondere negativa

-Toti pixelii aprinsi corect, iesirea este $7 - 6 = 1$

-Un pixel din cei corecti stins, iesirea este $6 - 6 = 0$

12. Dati ex unde si in ce alg de invatare si cum se aplica euristica de alegere a ipotezei de invatare.

13. Descrieti structura si modul de functionare al unui LSC. (ce e aia? :)))

14. Construiti o retea perceptron care sa reprezinte functia SI logic, SAU logic, etc .

15. Asta e rezultatul cerintei (deduceti voi cerinta).






Fig.3 Două rețele pentru învățarea funcției logice XOR






Asta de Si logic e bun??? cat e teta pt stratul de iesire?

Desenul este pentru XOR. Teta pt stratul de iesire este 0.

Retea care selecteaza maximum a doua intrari reale



- $f_3(t) = t$



- f_1 functie de transfer treapta



- $f_2(t) = t$ daca $t \geq 0$
 $-t$ daca $t < 0$

16. Sa se proiecteze o retea neurala care are la intrare un numar intre 0-20 si se activeaza la iesire pentru un numar >9 (sau cu doua iesiri, a doua iesire va avea un numar >9). Intrari, iesiri, algoritm, functie de transfer, valoare threshold.

O intrare cu ponderea 1

Threshold = -9.ceva

$x - 9 > 0$ cand $x > 9$ deci functia treapta

Nu stiu daca am inteles la partea a doua dar (ia un numar mai mare ca noua si scoate un numar mai mare ca noua) (ponderea e 1 functia de transfer e $f(x) = x$ threshold e 0)

17. selectie ruleta, se selectau 4 părinti dintr-un eșantion de indivizi cu fitness 5,10, 15, 20.care este numarul estimat de selectii ale individului cu fitness 5?

Nr Individ	1	2	3	4
Fitness	5	10	15	20
Probabilitate	0.1	0.2	0.3	0.4

$p(\text{alegere 1}) = 0.1 + 0.9 * 0.1 + 0.9^2 * 0.1 + 0.9^3 * 0.1 = 0.3439$, da' asta n-are treaba cu problema

18. Pentru un algoritm genetic cu indivizi reprezentati real, care utilizeaza recombinarea discreta (discrete recombination) se dau:

individual1: 13 2 10 4

individual2: 20 40 60 50

sample1: 2 2 1 1

sample2: 1 2 1 2 (sample 1 si sample 1 generate aleator)

Sa se indice doi descendenti (offspring1 si offspring2) subiniind in fiecare descendent valorile care provin din individual1. Justificati pe scurt cum ati obtinut descendentii.

individual1: 13 2 10 4

individual2: 20 40 60 50

sample1: 2 2 1 1

sample2: 1 2 1 2

offspring 1 (pt sample1) 20 40 10 4

offspring 2 (pt sample2) 13 40 10 50

In recombinarea reala discreta, unde sample are 1, se ia din primul individ, unde are 2 se ia din al doilea.

19. Intr-un alg genetic se considera urmatoarii 2 parinti: p1: 128 255 50 17 2 si p2: 123 4 344 280
 12. Construiti cei 2 copii obtinuti prin recombinare reala discreta avand sample1: 2 2 1 1 2 si
 sample 2: 1 2 1 1 2. Justificati pe scurt cum ati obtinut descendenti.

p1:	128	255	50	17	2
p2:	123	4	344	280	12
sample1:	2	2	1	1	2
sample2:	1	2	1	1	2

offspring1: 123 4 50 17 12

offspring2: 128 4 50 17 12

In recombinarea reala **discreta**, unde sample are 1, se ia din primul individ, unde are 2 se ia din al doilea.