
Invatare Automata Tema - Etapa 1 Lucian-Florin Grigore 343C4

Facultatea de Automatica si Calculatoare Universitatea Politehnica, Bucuresti


Codul sursa al acestei lucrari poate fi gasit in Google Colab la acest link.


Cerinta 1. Exploratory Data Analysis


Frecventa de aparitie a claselor in setul de date pentru UWaveGesture



Observam ca setul de date UWaveGesture contine un numar egal de clase atat in setul de antrenare, cat si in cel de testare.









Pentru fiecare serie temporala am luat din setul de antrenare primul exemplu din clasa respectiva.


Distributia valorilor per fiecare axa, per gest






Se poate observa ca majoritatea datelor se afla intr-un interval relativ restrans, ceea ce ar putea reprezenta o dificultate in antrenare, atunci cand se doreste optimizarea modelului si obtinerea unei acuratete foarte buna.


Frecventa de aparitie a claselor in setul de date pentru UWaveGesture dataset








Observam ca setul de date PEMS-FS contine un numar inegal de clase atat in setul de antrenare, cat si in cel de testare. Cu toate acestea, nu se poate considera nicio clasa redundanta, toate avand un numar apropiat de exemple.

Varierea ratei de ocupare pentru top 10 senzori cu deviatia cea mai mare pentru 8 zile selectate arbitrar uniform din totalul zilelor

















127.0 255.0 284.0 345.0 431.0 457.0 509.0 630.0 732.0 760.0 idx



46.0 277.0 446.0 498.0 618.0 667.0 736.0 739.0 771.0 938.0 idx






In urma analizei acestor grafice, cu mici exceptii, se observa cum majoritatea valorilor inregistrate de senzorii selectati se afla inspre limita inferioara a spectrului de valori. Asta poate reprezenta 2 lucruri:

1. Senzorii care au valori inregistrare mai mici (poate prin amplasarea lor in locatia respectiva) au si o sensibilitate la variatie, rezultand date mai imprastiate comparativ cu ceilalti senzori.

2. Posibil ca toti senzorii sa aiba valori mai apropiate de limita inferioara si atunci e nevoie de un pas in plus la preprocesarea datelor, dupa confirmarea acestei supozitii.

Evolutia mediilor celor mai relevanti 10 senzori pe durata tuturor celor 440 de zile



Putem remarca ca valorile in general sunt restranse intr-un interval mic de valori, apropiat destul de mult de origine.

Cerinta 2. Pentru cerinta a doua am folosit datasetul UWaveGesture

Feature Selection: Pentru a reduce datele de input la o dimensiune care poate fi gestionata si mai usor de analizat, am aplicat urmatoarele operatii:

- Am impartit fiecare axa (x, y si z) in ferestre de lungime 105 -> rezulta 3 ferestre per fiecare axa = 9 ferestre in total
- Pentru fiecare astfel de fereastra am facut media valorilor din seria de timp
- O intrare X din setul de date reprezinta aceste 9 valori obtinute in urma operatiilor de mai sus

In continuare, analiza atributelor si antrenarea modelelor este realizata pe aceasta noua reprezentare a datelor.

Extragerea atributelor

```
Applying mean on x_{axis}: -1.1325396825710079e-07
Applying mean on y_axis: -1.191991341994739e-07
Applying mean on z axis: -2.6096681093963078e-08
Applying std on x axis: 0.6537793630419304
Applying std on y axis: 0.7495870421412952
Applying std on z axis: 0.7088489128654653
Applying avg absolute diff on x axis: 0.5317972085502645
Applying avg absolute diff on y_axis: 0.6496156217923061
Applying avg absolute diff on z_axis: 0.6049543094942061
Applying min on x_axis: -1.363360857142857
Applying min on y axis: -1.3331605714285715
Applying min on z axis: -1.3638615238095237
Applying max on x axis: 1.360968380952381
Applying max on y_axis: 1.3764914000000001
Applying max on z axis: 1.33198819047619
Applying max-min diff on x axis: 2.7243292380952377
Applying max-min diff on y_axis: 2.7096519714285714
Applying max-min diff on z axis: 2.695849714285714
Applying median on x axis: -0.02353086190476192
Applying median on y axis: 0.03759409047619046
Applying median on z axis: 0.09206555714285715
Applying median abs dev on x axis: 0.45422849999999999
Applying median abs dev on y_axis: 0.6274349095238094
Applying median abs dev on z axis: 0.548894542857143
Applying IQR on x axis: 0.91\overline{2}718819047619
Applying IQR on y_axis: 1.2576291285714287
Applying IQR on z axis: 1.158704673809524
Applying negative count on x axis: 632
Applying negative count on y axis: 673
Applying negative count on z axis: 716
Applying positive count on x axis: 688
Applying positive count on y axis: 647
Applying positive count on z axis: 604
Applying values above mean on x axis: 632
Applying values above mean on y_axis: 673
Applying values above mean on z_axis: 716
Applying values below mean on x axis: 688
Applying values below mean on y axis: 647
Applying values below mean on z axis: 604
Applying number of peaks on x axis: 451
Applying number of peaks on y_axis: 442
Applying number of peaks on z axis: 441
Applying skewness on x axis: 0.09000602953872863
Applying skewness on y_axis: -0.07910393643284531
Applying skewness on z_{axis}: -0.18151097976780978
Applying kurtosis on x axis: -0.7231033556102662
Applying kurtosis on y axis: -1.181820388478901
Applying kurtosis on z axis: -1.0416019685057663
Applying energy on x axis: 5.642042413121732
Applying energy on y axis: 7.416825685449181
Applying energy on z axis: 6.632561512771293
Average resultant acc is 44.3750263226313
Signal magnitude area is 1.786367140079365
```

De pe urma acestor metrici, valorile obtinute nu indica vreo anomalie evidenta.

Antrenare de modele ML

Folosind percentile=10 (valoarea default din sklearn) am fi folosit doar un atribut din cele 9, ceea ce este destul de riscant intrucat se pierde foarte multa informatie pentru fiecare exemplu.


Rezultate pentru folosirea Select Percentile cu percentile=50, adica folosirea a 4 din 9 atribute per fiecare intrare din dataset

Rezultate pentru folosirea Select Percentile cu percentile=100, adica folosirea tuturor celor 9 din 9 atribute per fiecare intrare din dataset

Pentru XGBoost learning_rate joaca un rol foarte important. Pentru SVC, kernelul "rbf" pare a fi cel mai constant dpdv al performantei obtinute. De asemenea, pare ca valoarea de 0.15 pentru "C" este ideala intrucat ofera cele mai bune performante. Random Forest pare ca prefera un numar finit de estimatori si o adancime maxima care nu este infinita. Dar aici intervine si dimensiunea relativ scazuta a setului de date.

Observam ca in mod constant Support Vector Machine Classifier obtine cea mai buna acuratete pe setul de antrenare. Am considerat in continuare modelul antrenat folosind percentile=50, intrucat acuratetea la antrenare este aceeasi, dar volumul de date este considerabil mai mic, imbunatatind astfel performanta.

	General Accuracy	Classes	1	2	3	4	5	6	7	8
Classifiers and Parameters (best performing)										
Random Forest										
Bootstrap: False	Train: 0.8	Precision	0.73	0.66	0.67	0.91	0.68	0.81	0.65	0.72
Max_depth: 50,	Test: 0.72	Recall	0.82	0.77	0.87	0.52	0.9	0.65	0.52	0.65
N_estimators: 50		F1	0.77	0.76	0.76	0.66	0.77	0.72	0.58	0.68
Support Vector Machine										
C: 0.15	Train: 0.83	Precision	0.85	0.88	0.84	0.87	0.69	0.83	0.9	0.72
Kernel: rbf	Test: 0.81	Recall	0.87	0.92	0.9	0.7	0.95	0.72	0.5	0.9
		F1	0.86	0.9	0.87	0.77	0.8	0.77	0.65	0.8
XGBoost										
Learning_rate: 0.2	Train: 0.73	Precision	0.79	0.72	0.74	0.86	0.7	0.79	0.56	0.61
Max_depth: 2	Test: 0.72	Recall	0.77	0.9	0.87	0.62	0.85	0.75	0.35	0.67
N_estimators: 150		F1	0.78	0.8	0.8	0.72	0.77	0.77	0.43	0.64



- 35


30


- 25

- 20

- 15

- 10





Mai sus sunt prezentate rezultatele pentru cea mai buna combinatie de parametrii pentru fiecare algoritm, urmarind: acuratetea generala, recall, precision si F1 (ultimele trei la nivel de clasa).

De asemenea, sunt afisate matricile de confuzie pentru acesti algoritmi.

Toate aceste date sunt obtinute de pe urma predictiilor pe setul de testare.